
2025 年全国大学生信息安全竞赛

作品报告

作品名称: SonicGuard: 基于对抗扰动的语音隐私主动防御系统

电子邮箱: 1102276166@qq.com

提交日期: 2025/6/25

填写说明

1. 所有参赛项目必须为一个基本完整的设计。作品报告书旨在能够清晰准确地阐述（或图示）该参赛队的参赛项目（或方案）。
2. 作品报告采用A4纸撰写。除标题外，所有内容必需为宋体、小四号字、1.5倍行距。
3. 作品报告中各项目说明文字部分仅供参考，作品报告书撰写完毕后，请删除所有说明文字。（本页不删除）
4. 作品报告模板里已经列的内容仅供参考，作者可以在此基础上增加内容或对文档结构进行微调。
5. 为保证网评的公平、公正，作品报告中应避免出现作者所在学校、院系和指导教师等泄露身份的信息。

目 录

摘要.....	1
1 作品概述.....	2
1.1 研究背景分析.....	2
1.2 相关工作.....	5
1.3 特色分析.....	8
1.4 应用前景分析.....	9
2 作品设计与实现.....	11
2.1 系统模型.....	11
2.2 系统设计思路及其原理.....	14
2.3 系统实现.....	22
3 作品测试与分析.....	32
3.1 测试方案.....	32
3.2 测试环境.....	32
3.3 数据集与评价标准.....	34
3.4 结果展示和分析.....	37
4 创新性说明.....	45
4.1 源头防御的技术原理革新落地.....	45
4.2 轻量化模块化的系统架构突破.....	45
4.3 动态多维的测试评估体系.....	46
5 总结.....	47
5.1 作品总结.....	47
5.2 推广与展望.....	48
参考文献.....	50

摘要

语音合成与语音克隆技术在深度学习技术的推动下取得了飞跃式进展，从最早的语音合成模型 WaveNet、Tacotron2 到 FastSpeech、StyleTTS 等，再到基于多模态协同训练的情感语音合成模型，如今只需几秒语音样本便可合成与目标说话人音色极为相似的语音。然而，随着语音合成技术的成熟，声音伪造攻击也逐渐渗透至金融、社交、政务、司法等多个高敏感领域，催生了极具隐蔽性和破坏力的 DeepFake 语音攻击链。

在此背景下，本作品设计了一种语音隐私主动防御系统——SonicGuard。该系统创新性地将防御策略前置至语音样本发布阶段，采用对抗扰动技术向用户音频中注入不可感知的扰动，从而在源头破坏语音合成模型对说话人身份的有效建模。与传统依赖后验检测的方案不同，SonicGuard 实现了对 DeepFake 攻击链中“数据输入端”的前置破坏，有效抑制语音伪造的可能性，真正实现了主动防御。

SonicGuard 系统基于多目标对抗优化框架，实现对说话人嵌入空间的高效干扰，同时最大程度保障原始语音的听感自然性。系统构建了以 VAE、LSTM、ResNet 和 Transformer 为代表的四类异构声学编码器，采用自适应梯度融合机制，提升扰动的跨模型迁移能力，从而在攻击者模型未知的黑盒场景中依然具备强防御力。在不可感知性方面，系统引入等响度曲线和听觉掩蔽效应，设计频率惩罚机制与信噪比调控策略，确保扰动在人耳敏感频段的能量不超过-35dB，并动态适应不同频谱环境，实现听觉隐蔽性与防御效能的双重优化。

本系统在架构层面采用前后端分离设计：前端基于 Vue 与 WebAssembly 实现浏览器本地扰动注入，用户无需高算力支持，适配通用终端设备；后端采用 Python-Django 构建服务端逻辑，支持音频处理、检测、用户管理与历史记录管理。整体系统具有轻量化、高扩展性、高易用性的特点，用户仅需上传音频，即可一键完成防伪处理或测试，显著降低使用门槛。

为验证系统性能，本团队构建了“安全性—实用性—可用性”三维评估体系，对系统进行了全面测试。结果显示，在真实业务场景中，处理后的音频被声纹认证系统识别的相似度平均得分为 0.41，可以有效阻断语音克隆攻击；主观盲测实验结果 MOS 评分平均为 4.32 分，PSD 平均为 4.05，这表明了系统生成的扰动对语音内容可辨识度无显著影响。保障了用户的听觉体验与日常可用性。

关键词：语音防伪造、对抗扰动、主动防御系统、多目标对抗优化

1 作品概述

1.1 研究背景分析

语音合成技术的快速发展与安全隐患正形成技术伦理领域的核心矛盾。在深度学习与物理声学的双重驱动下，语音合成已突破机械发声的桎梏。WaveNet 通过空洞因果卷积实现 16kHz 以上高分辨率音频生成，消除传统声码器的金属音纹^[1]。Transformer 模型的多头自注意力机制让系统能动态捕捉文本语义与声学特征的关系，使得疑问句语调自然度提升 42%^[2]。然而在相对应的语音检测领域，目前主要受到语音伪造的威胁，主要的威胁方式为合成攻击、对抗攻击和重放攻击等等^[3]。作为威胁方式之一的语音合成技术进步不仅体现在基础模型，更通过多模态联合训练实现跨越——StyleTTS 模型融合声纹、面部表情数据，同步调整基频波动与口腔开合参数，生成情感-语音-视觉协调的输出，甚至用三分钟语音样本即可重建喉癌患者的个性化声库^[4]。实时性优化方面，FastSpeech 2 通过音素级时长预测将合成速度提升至传统模型的 200 倍，配合动态量化感知训练实现移动端 10ms 级延迟，这种高效性推动智能客服、车载导航等场景的普及^{[5][6]}。

然而，技术突破的背面是日益严峻的安全风险。声音盗用已成为黑色产业链的核心手段，开源工具 SV2TTS 仅需 20 秒即可克隆特定声纹，诈骗分子利用三秒语音样本生成高仿声线实施金融欺诈。2025 年四川泸州陈女士遭遇的亲情诈骗案中，犯罪分子仅用 3 秒社交平台语音样本，通过 GAN 算法生成女儿被绑架的求救声，并叠加医院环境音效，成功骗取 80 万元。浙江大学区块链与数据安全全国重点实验室的研究揭示了技术滥用的普遍性——基于 7000 多名说话人的语音数据和 5 种主流克隆工具测试显示，语音克隆攻击对智能音箱达到 76%，而人类听辨准确率低至 50%，近乎盲猜水平^[7]。

在金融领域，香港某跨国公司的深度伪造会议诈骗案中，攻击者从公开视频提取 5 名高管声纹，生成实时对话语音突破企业风控系统，造成 2 亿港元损失。此类案件并非孤例，国家反诈中心数据显示，2025 年 1 月至 2 月全国 AI 语音诈骗涉案金额超 5.2 亿元，98% 受害者表示“声音与亲友完全一致”。更令人担忧的是，黑市兜售的“AI 克隆工具箱”已形成产业链，30 秒语音样本即可生成专业配音员水平的声纹，某国有银行测试显示克隆语音突破声纹转账系统的成功率高达 76%。

公众人物声音因为有社交平台公开的音频，滥用更加猖獗。国家传染病医学中心主任张

文宏的门诊录音被截取生成带货语音，某保健品直播使用其合成声音宣称“蛋白棒增强免疫力”，单条视频播放量超 500 万次。政治领域的风险更为严峻，2025 年伪造美国副总统音频事件中，虽然基频抖动率异常值达 8.2%（正常人类语音<3%），仍引发特斯拉股价单日波动 4.7%，暴露金融市场对语音伪造的脆弱性。




图 1-1 语音欺诈基本流程

智能化时代，语音信息被广泛采集，隐私泄露风险呈现指数级增长。某智能音箱厂商未经授权使用 10 万小时用户语音数据训练商业模型，其中 2.3 万条儿童声纹在黑市以每条 0.5 美元交易。技术测试表明，通过开源工具 Resemble AI，仅需在电脑播放录音即可绕过实时录音验证，ElevenLabs 等平台生成 1 分钟高仿语音最快仅需 3 秒，且 5 家主流平台完全免费开放。更隐蔽的是声纹逆向工程，中科院模式识别实验室通过改进的多模态特征融合算法，仅需 20 秒的合成语音即可反推目标个体的共振峰分布、基频波动模式及声道几何特征等生物特征。实验数据显示，合成语音的谐波噪声比（HNR）偏差小于 1.2dB，与真实语音的频谱分布高度吻合。该研究采用 7000 余名说话人的语音数据进行测试，结果表明专业鉴伪设备的误判率高达 82%，传统声纹验证系统的可靠性受到根本性挑战^[8]。

现有防御体系在技术狂潮面前显得力不从心。被动检测模型的等错误率（EER）高达 16%，而动态水印技术在无伪造标记时 EER 超过 80%。滑铁卢大学研发的新型 DeepFake 软件甚至能在 6 次尝试内实现 99% 的语音认证突破率，暴露出当前声纹锁的安全漏洞。人类听觉

系统的分辨能力远低于自动检测系统，存在天然缺陷。其误判率（EER）可达约 50%，几乎等同于随机判断。这些数据印证了技术攻防的严重失衡——当犯罪成本降至数百元（开源工具价格）而防御成本呈几何级数增长时，个人与社会安全防线正遭遇前所未有的冲击。

技术防御与法律治理正形成双重应对体系。在检测层面，基于长时窗口恒定 Q 变换（CQT）的特征提取技术，通过捕捉子带级别的频谱异常，将合成语音识别准确率提升至 98.7%，而动态水印技术可在音频中植入不可逆标识，实现传播溯源^[9]。法律层面，中国《AI 声音合成管理条例》要求商业应用必须声源授权，新加坡则通过迭代更新的 AI 治理框架，强制合成内容标注“人工智能生成”标识。行业协作方面，谷歌开放包含 68 种口音的合成语音数据库，助力 ASVspoof 挑战赛开发反欺诈算法，科技公司 Pindrop 研发的深度残差网络能识别语音中违背人类发音模式的微观特征。公众教育同样关键，媒体正普及“四步验证法”：核查异常停顿、基频稳定性、环境噪音一致性及情感波动合理性。

然而不管是监测还是立法，都需要依赖技术层面的进步。而技术进化的未来将走向“防御内嵌”模式。随着深度学习的发展，目前合成语音检测系统主要采用深度神经网络用于构建特征表示和分类网络。这些系统充分利用神经网络的特征学习能力，首先对输入特征进行学习，然后进行高级特征的表示和分类。当前研究主要集中在特定攻击类型或基于特定数据集，导致单一系统难以有效地检测各种合成攻击（例如 TTS、VS 和 TTS-VC 混合等），以及未知攻击在训练集中的缺失。由于难以事先知晓具体攻击类型，因此最新研究普遍致力于提升检测系统的泛化性能，即设计通用的检测系统，能够跨越不同合成攻击类型，并能够抵御不同通道环境中的噪声干扰。

基于以上挑战和问题，本作品的意义在于构建一种主动防御范式，为当前 DeepFake 语音治理体系中关键的技术提供了可行的方法。现有检测方案虽能事后识别合成语音，却无法阻断攻击源头——即攻击者利用公开语音样本训练高仿真的合成模型。SonicGuard 通过逆向利用对抗机器学习的特性，将防御节点前置至语音样本发布阶段，从根本上破坏语音合成模型对说话人身份的提取能力。在防御逻辑的革新上，提出“预防优于检测”的新路径，通过在语音样本中嵌入人耳不可察的对抗扰动，使攻击者无法生成具有身份欺骗性的合成语音，从源头瓦解 DeepFake 攻击链；针对黑盒攻击场景设计扰动生成机制具有强迁移性，通过集成异构说话人编码器捕捉跨模型的通用声学特征，确保防御对未知合成器的泛化能力；同时，建立轻量化人机交互框架，仅需用户上传待处理的对话音频，不需要进行任何技术性的决策，

在保障防御效能的同时降低使用门槛，为公众提供可落地的语音保护工具。这种防御范式不仅为个人语音隐私建立了第一道防线，更通过扰乱攻击者的数据供应链，为构建“检测-预防”协同的多层次 DeepFake 治理体系提供关键技术支撑，对遏制金融诈骗、身份盗用等现实威胁具有迫切应用价值。

1.2 相关工作

DeepFake 主动防御技术的核心在于干预语音合成过程，通过在原始音频公开发布前嵌入特定信息，直接破坏伪造模型的输出或实现溯源认证。

1.2.1 基于深度学习的声学提取方法

基于深度学习的声纹特征提取技术的核心目标是，从原始音频波形或声学特征（如 MFCCs, Filterbanks）中学习到一个固定长度的、低维的向量表示，这个向量能够最大程度地表征说话人身份信息，区分不同说话人，而对语速、内容、信道、背景噪声等因素具有鲁棒性。

早期 DNN 声纹嵌入（d-vectors）通过训练深度分类网络实现，输入帧级声学特征（如 MFCCs 或 Filterbanks），利用 DNN、CNN 或 LSTM 提取时序特征，并通过时间池化（如平均池化或注意力加权）聚合为固定长度向量。该向量通常从紧邻分类层之前的瓶颈层提取，以多说话人分类损失优化模型，其判别性显著优于传统方法^[10]。

x-vectors 进一步提升了鲁棒性与标准化流程：采用时延神经网络（TDNN）或 LSTM 处理帧级特征，创新性地引入统计池化层计算全局均值和标准差，形成描述语音统计分布的特征向量。该向量经全连接层压缩后获得紧凑嵌入，并通过大规模数据增强（噪声、混响模拟）显著提升了模型对信道差异和噪声的适应能力，成为声纹识别的基准框架^[11]。

后续研究聚焦增强特征判别效率，代表性工作如 Desplanques 等人^[12]提出的 ECAPA-TDNN，其通过三项关键改进突破性能瓶颈：1.层级多尺度建模：在 TDNN 层中嵌入 Res2Net 模块，将特征分组并级联处理，显式构建多尺度表示以捕捉更丰富的声学细节；2.通道注意力机制：在 Res2Net 后添加 SE（Squeeze-and-Excitation）模块，动态学习通道重要性权重，突出判别性特征；3.深度特征聚合：融合网络中多层抽象特征后输入统计池化层，最大化利用不同粒度的说话人信息。该架构在短语音场景下表现尤为优异。

近年兴起的自监督学习技术如 wav2vec 2.0，则从根本上改变了特征学习范式。模型通过

掩码对比任务从海量无标签音频中预训练：特征编码器（多层 CNN）将原始波形转化为潜在表示后，Transformer 上下文网络预测被掩码片段的正样本并排斥负样本^[13]。学习到的通用语音表示蕴含显著说话人信息，可通过监督微调和零样本推理两种方式用于声纹任务。

基于深度学习的声纹提取方法提取的声纹嵌入兼具高紧凑性与强判别性，为音频水印中的身份认证提供了理想的特征源。其核心价值在于平衡了身份信息的有效编码与对声学干扰的鲁棒性。

1.2.2 基于对抗样本的主动防御

基于对抗样本的主动防御机制的核心思路是在原始音频中巧妙添加人耳难以察觉的细微扰动，以此干扰攻击模型（如语音合成或语音转换模型），使其无法生成逼真、有效的伪造音频，进而保障音频内容的真实性与安全性。

在技术革新上，2023 年 Yu 等人^[14]提出 AntiFake，主要针对语音合成模型展开防御。它创新性地对说话人编码器的输出特征进行扰动操作，通过设计的算法改变特征向量的分布，使得原本能够通过 TTS，精准模拟目标说话人音色的合成语音，经过扰动后严重偏离原说话人音色。实验数据显示，在白盒场景下，AntiFake 的防御成功率近乎完美，高达 100%。这意味着在攻击者模型结构与参数已知的情况下，AntiFake 能够可靠地识别并抵御伪造音频的合成，为语音安全筑起一道坚固防线。不过，在黑盒场景中，由于对攻击者模型信息掌握有限，AntiFake 的防御性能可能会受到一定影响。

2024 年，Dong 等人^[15]提出基于生成对抗网络（GAN）的防御框架，利用对抗学习机制实现扰动的快速生成。该框架构建了由生成器与判别器组成的动态博弈系统：生成器以最小化攻击模型输出质量为目标，生成对抗扰动；判别器则通过二分类任务区分原始音频与扰动音频。在对抗迭代过程中，生成器逐渐掌握能够干扰攻击模型的扰动模式。同时，频谱波形转换模块（SWCSM）的引入，从频域与时域双维度优化扰动信号的特征分布，显著提升防御的泛化能力。实验数据表明，该方法将扰动生成时间压缩至 0.27 秒，较传统基于梯度迭代的方法提升了数十倍的处理效率，能够满足实时音频防护场景下的高时效性需求，为防御系统的工程化部署提供了技术可行性。

1.2.3 基于多通道麦克风阵列的检测技术

基于多通道麦克风阵列的检测技术借助智能设备内置的多麦克风阵列（如智能音箱的环形麦克风阵列），实时捕捉声音信号的空间传播特征，包括声波到达不同麦克风的时间差

（TDoA）、到达角度（AoA）以及相位差等三维空间信息，结合深度学习模型构建跨模态特征识别体系，实现人类语音与机器生成音频的精准区分。

2021 年，Li 等人^[16]提出的多通道幅相谱图分析模型具有优异的检测性能。该模型首先将多通道麦克风采集的时域信号转换为包含幅度谱与相位谱的三维特征矩阵，随后利用卷积神经网络（Convolutional Neural Network, CNN）提取跨通道的空间 - 频谱联合特征，并通过注意力机制强化对关键空间特征的识别。在公开音频攻击检测数据集上的实验表明，该模型对重放攻击、语音合成攻击等 5 类伪造音频的平均检测错误率（Equal Error Rate, EER）低至 6.6%，充分验证了基于空间特征与深度学习结合的检测方案的有效性。然而，当模型应用于新环境时，检测错误率上升至 8.8%，这一现象表明环境声学特征，如混响、背景噪声分布等因素，会对空间特征检测产生一定影响。

1.2.4 数字水印与信息嵌入技术

数字水印与信息嵌入技术在身份认证领域的深化应用，依托端到端联合训练、零样本声纹认证及动态安全机制的协同创新，实现身份绑定与攻击鲁棒性的统一优化。

端到端联合训练框架通过整合声纹特征提取、水印编解码和认证模块，构建闭环优化系统。核心采用对抗性训练策略，其中生成器将声纹向量编码为不可感知的扰动并注入宿主音频，同时判别器模拟信道攻击（如 MP3 压缩、加性噪声及语音克隆），迫使水印提取器在攻击环境下稳定重建声纹特征。该架构通过包含水印重建损失最小化载荷误差、声纹保真度损失维持特征判别性、音频质量损失则约束波形失真在内的多目标损失函数优化，提高编码的准确率。实验表明，联合训练可使重建声纹与原始向量的均方误差降至 0.05 以下，在 96kbps OPUS 编码和音色转换攻击下认证准确率保持 91%以上^[17]。

零样本声纹认证技术则革新了传统依赖注册库的模式。该方法基于自监督模型的普适声学表示，例如截取 wav2vec 2.0 的 Transformer 中间层输出（第 6 层帧特征均值与标准差），经 PCA 降维生成 8-bit 轻量化指纹。该指纹通过扩频技术嵌入 300Hz 以下低频带，利用 DSSS 调制增强抗噪性。认证端直接比对提取指纹与注册指纹的汉明距离，阈值 $\theta=0.25$ 时错误接受率仅 3.5%，且在边缘设备上实现 95ms 延迟的实时决策。此方案突破性地避免了声纹数据库的建立与维护，适用于跨设备认证场景，在 VOICECON 跨语种测试中达到 94.2%的等错误率^[18]。

动态安全机制通过密钥绑定与特征融合构建双重防护。密钥系统采用时间戳绑定策略，动态派生 128 位会话密钥，用于加密声纹指纹并生成 HMAC 校验码。水印负载并联声纹特征

与内容特征（32 位梅尔谱哈希），形成认证流水线：首先检测内容完整性，汉明距离 >0.1 即报警，再解密声纹特征进行余弦相似度比对，决策阈值 $\theta=0.35^{[19]}$ 。多重特征融合能够显著提升防伪能力，实验显示当 30%音频被 DeepFake 替换时，内容哈希检测触发率达 98%，同步声纹认证准确率保持在 86%。当前研究正探索后量子密码迁移，以应对量子计算威胁，并利用扩散模型生成与声纹特征协同优化的不可听扰动^[20]。

1.3 特色分析

1.3.1 对抗扰动的主动防御机制

基于“预防优于检测”的防御理念，系统于语音样本发布环节，植入符合人类听觉掩蔽效应的不可感知对抗扰动。该扰动精准作用于声纹特征提取核心环节，通过干扰基频轮廓、共振峰分布等生物声学特征，阻断语音合成模型对说话人身份的建模进程。

在技术实现上，系统采用多编码器联合优化策略，创新性集成 VAE、LSTM、ResNet、Transformer 四类异构声学编码器，并通过自适应加权机制实现梯度信息的动态融合。这种架构设计有效提升了扰动的泛化能力，能够适应不同语音合成模型的特征空间。

该方案在 Tacotron2、FastSpeech2 等 5 类主流语音合成器中，黑盒防御成功率均达到 95% 以上，相较于传统单模型优化方案，平均防御效能提升 27.6%，充分展现了其在语音隐私主动防御领域的显著优势。

1.3.2 轻量化人机协同架构

为突破对抗训练对 GPU 算力的高度依赖，本系统采用浏览器端实时扰动注入引擎。

在前端计算架构层面，通过 WebAssembly 与 JavaScript 的深度融合，实现模型轻量化设计。将原本复杂的 256 维声纹嵌入计算进行高效压缩，最终形成仅 12MB 的可执行文件，大幅降低前端计算资源消耗，提升运行效率。

动态感知优化模块依托 ISO 226 等响度曲线理论，构建专业的心理声学优化器。该优化器针对人耳听觉特性进行精准调控，在 1-3kHz 人耳敏感频率区间，严格将扰动能量控制在 $\leq -35\text{dB}$ ，以避免对听觉体验产生明显干扰；在高频区 ($>8\text{kHz}$)，则依据实际情况智能分配剩余扰动，在保障防御效果的同时兼顾音频质量。

在效率表现上，系统展现出卓越性能。处理 30 秒音频时，在 CPU i5-12400F 配置下，耗时可控制在 26 秒以内，经 50 份样本测试，平均 MOS 评分达 4.32 ± 0.18 ，成功实现了防御效能

与用户体验的良好平衡。

1.3.3 动态多维评估体系

为系统性量化评估语音安全防护系统性能，本研究创新性构建“安全性 - 实用性 - 可用性”三维评估矩阵，从多维度验证系统核心价值，具体评估分析如下：

在安全性维度，依托 ASVspoof 2023 这一国际权威语音反欺骗测试集，对系统抵御 TTS（文本转语音）-VC（声纹转换）混合攻击的能力展开专项验证。测试结果显示，系统成功将等错误率（Equal Error Rate, EER）从行业基准水平显著降低至 3.8%。这一指标的突破性优化，意味着系统在复杂语音伪造攻击场景下，能够精准识别真伪语音，有效降低错误接受与错误拒绝概率，为语音安全防护构筑起可靠的技术防线。

实用性维度评估中，通过接入科大讯飞声纹认证 API，模拟真实业务场景下的声纹识别过程。数据显示，经系统处理后的伪造音频，其认证相似度从原始的 89.7% 大幅下降至 41.2%，远低于 60% 的认证阈值。这一显著变化表明，系统可高效削弱伪造语音与真实声纹的匹配度，大幅提升声纹认证系统对欺诈音频的拦截能力，在金融、安防等对声纹认证准确性要求极高的领域具备极强的落地应用价值。

可用性维度则通过大规模用户盲测实验进行验证。研究团队组织 20 名不同背景用户参与测试，采用 5 分制量表对原始语音与合成语音的可区分度进行主观评分（PSD 值）。该结果可以验证系统在保障安全性能的同时，未对语音内容的可辨识度造成显著影响，也确保了在实际应用场景中，用户能够基于直观感知有效参与语音安全鉴别，实现技术性能与用户体验的有机统一。

1.4 应用前景分析

SonicGuard 系统的核心原理在于，通过在语音样本中嵌入人耳难以察觉的微小扰动，干扰语音合成模型对目标说话人特征的学习过程，从源头上削弱语音伪造的可行性。这种主动防御机制不仅具备技术创新性，更因契合现实需求而极具应用价值。

在金融领域，声纹识别已成为身份验证的重要手段，被广泛应用于手机银行声纹解锁、线上支付声纹认证等场景。但随着语音克隆技术的成熟，犯罪分子可利用公开渠道获取的语音数据，合成与目标用户高度相似的语音，绕过声纹认证系统实施金融诈骗。SonicGuard 系统可接入用户日常语音交互环节，在语音数据生成时即添加对抗扰动，使攻击者获取的语音

样本失去克隆价值。这一举措既能守护用户资金安全，也能帮助金融机构构建更完善的风控体系，减少因语音欺诈导致的经济损失，进一步巩固客户对金融服务的信任基础。

社交娱乐领域同样面临语音安全威胁。用户在社交平台分享语音动态，或在娱乐应用中进行语音互动时，其语音内容一旦公开，就存在被非法采集和滥用的风险。公众人物的语音资料更是因传播范围广，成为语音伪造的“重灾区”，常被用于制作虚假广告、恶意谣言等^[21]。SonicGuard 系统为用户提供了有效的语音防护方案，在音频发布前自动对语音进行安全处理，有效降低语音被克隆和伪造的风险。这不仅保护了用户的个人身份与声誉，也为社交平台营造健康有序的内容生态提供了技术保障。

智能客服与智能家居领域对语音安全的需求同样迫切。智能音箱、语音助手等设备通过语音交互完成指令执行、信息查询等操作，用户语音数据在设备端与云端之间频繁传输，数据泄露风险较高^[22]。一旦攻击者获取这些语音数据，便可通过语音克隆技术操控智能家居设备，甚至窃取用户敏感信息。SonicGuard 系统可集成至智能设备的语音交互模块，对传输中的语音数据进行实时加密防护，确保语音通信全程安全，为智能语音技术的深化应用扫除安全障碍。

在法律与政务领域，语音证据的真实性对司法审判至关重要，政务服务中的语音交互也涉及大量公民隐私信息。SonicGuard 系统可对司法取证、政务服务等场景中的语音记录进行安全加固，防止语音内容被篡改或伪造，保障语音证据的法律效力，同时提升政务服务的安全性与公信力。

科研与教育机构在开展语音相关研究、教学活动时，也需严格保护语音数据隐私。SonicGuard 系统为其提供了可靠的数据保护方案，既能保障科研数据的安全性，防止数据泄露影响研究成果，又能保护师生语音信息隐私，助力营造安全、合规的学术环境。

随着语音隐私安全受关注度攀升，SonicGuard 系统凭借主动防御与跨领域适配优势，精准匹配多行业需求。其在隐私保护、商业安全及技术合规等方面极具潜力。

2 作品设计与实现

2.1 系统模型

2.1.1 语音合成模型

DeepFake 语音合成模型主要基于深度神经网络（DNN）的现代架构，具备零样本（zero-shot）合成能力，即无需目标说话人的训练数据即可生成高度逼真的仿冒语音。这类模型广泛应用于语音克隆、虚拟人配音、语音交互等领域，但也面临被滥用于语音诈骗、身份冒用等安全威胁的风险。这种基于 DNN 的语音合成模型，称为 DeepFake^[23]。

DeepFake 语音合成模型的运作流程可系统拆解为以下核心步骤：

1、**音频预处理**：为确保数据格式统一，提升模型处理稳定性，需对原始语音进行系列预处理操作。包括通过重采样（Resampling）统一音频采样率；运用音量归一化（Volume Normalization）保证音频响度一致；执行静音修剪（Trimming Silence），移除冗余非语音片段。

2、**梅尔频谱图转换**：将预处理后的语音波形转换为梅尔频谱图，这一操作实现了声音时域信号向时间-频率二维表征的转化，有效凸显语音在音高、共振峰等关键频谱特征，为后续处理提供基础。

3、**说话人嵌入编码**：通过深度神经网络提取固定长度的说话人特征向量（通常为 128 维或 256 维），编码说话人独特的声学特征，如音色、发音习惯、韵律等。采用分帧处理策略，将音频切割为短时段分别提取部分嵌入，避免长时平均造成的特征模糊，精准捕捉局部声学特征，最后聚合形成最终嵌入，确保同一说话人不同语音片段的嵌入相近，不同说话人之间嵌入差异显著，赋予模型零样本合成能力。

4、**文本特征转换**：由于原始文本存在多音字、发音规则复杂等问题，难以直接处理，因此需将文本输入转化为音素或其他可被模型理解的语言学特征，如音高、时长、重音等，从而实现对合成语音发音的精准控制。

5、**音频生成**：借助 DNN 生成模型，将文本转换得到的编码内容与说话人嵌入进行融合，最终合成高保真、具备目标说话人声音特征的音频。若进一步结合声码器，还可将中间频谱表示重建为自然、连贯、听感逼真的语音波形，实现端到端的语音克隆。

DeepFake 工作流如图 2-1 所示。




图 2-1 DeepFake 工作流程

得到说话人嵌入后，模型结合文本输入进行条件合成。文本首先被解析为语言学特征（如音素序列），与说话人嵌入共同输入生成网络，输出预测的梅尔频谱图。最终，声码器将频谱图转换为高保真的波形音频，生成与目标说话人高度相似的 DeepFake 语音。整个流程呈现高度模块化特点：编码器、生成器与声码器可灵活替换，并通过多阶段优化实现对人耳感知和声纹认证系统的双重欺骗。

2.1.2 威胁模型

2.1.2.1 攻击动机

为实现恶意目的，攻击者常利用 DeepFake 技术合成与目标对象高度相似的语音，以此混淆视听。在现实世界场景中，此类攻击行为通常存在四种常见动机，其中前三种主要针对人类实施欺骗，最后一种则以欺骗机器为目标。

在金融领域，DeepFake 语音技术正沦为新型诈骗攻击。攻击者利用该技术，通过对公司高级管理人员、银行高层以及与受害者存在密切关系人员的声音进行克隆，营造出极为逼真的语音交互场景。凭借伪造身份与目标对象建立起的职务层级关系或情感联系，实施诈骗行为。在现实世界的典型案例中，2019 年，诈骗者依据公开的会议录音及社交媒体资料，克隆了英国某能源公司 CEO 的语音。随后，诈骗者通过电话联系该公司财务主管，以紧急事务为由，要求将 24.3 万美元转入匈牙利账户。财务主管未能识破伪装，完成转账操作。直至诈骗者再次要求转账时，异常情况才被察觉，但已转出资金难以追回。作为全球首例公开的音频 DeepFake 诈骗案件，伪造语音不仅在音色上高度相似，更精准复刻了该 CEO 的德国口音及语调习惯。

在安全与隐私领域，攻击者常利用 DeepFake 语音技术实施恶意行为。他们通过模拟同事、主管等可信人员的声音，与受害者进行语音交互。在沟通过程中，攻击者以工作要求、系统异常等理由，诱导受害者执行不安全操作，或骗取访问令牌、密码、个人身份信息等敏感数据，从而对个人及组织的安全与隐私造成严重威胁。在新冠疫情（Covid-19 Pandemic）期间，

便出现过此类恶意应用案例。攻击者运用 DeepFake 语音技术，伪装身份申请可接触企业机密数据的远程职位，其中涉及个人身份信息、财务数据以及企业 IT 数据库等核心信息，通过骗取企业信任获取岗位权限，从而为窃取敏感数据创造条件。

攻击者通过克隆公众人物或权威机构的声音，系统性地制造并传播仇恨言论、色情内容及虚假信息。其将恶意信息与目标对象进行绑定，利用公众对名人、权威的信任，达到操纵舆论、煽动对立、扭曲事实的目的。部分攻击者利用该技术克隆名人声纹，批量生产并扩散有害内容。此类行为不仅污染信息传播环境，更可能激化社会矛盾，动摇公众对信息真实性的信任基础，对社会稳定与公共安全形成严峻挑战。

绕过语音身份验证。在安全关键型系统中，基于语音的身份验证技术凭借个人声纹的独特生物特征，构建起重要的安全防护屏障，被广泛应用于身份核验与权限授予场景。然而，随着 DeepFake 技术的迭代升级，其通过深度机器学习算法对目标对象的语音特征进行精准建模与复刻，能够高度还原包括音色、语调、韵律在内的生物声学特性，致使传统语音身份验证机制面临严峻挑战。2023 年，公开报道的某起银行账户入侵事件证实了这一风险的现实存在——攻击者借助人工智能合成语音，成功绕过银行语音验证系统，非法获取账户访问权限。

表 2-1 语音样本库部分样例

application scenario	example
Financial fraud	I need money for an emergent surgery, please transfer me a thousand dollars.
	I need a grand for an emergency medical bill.
	I'm in trouble in a foreign country, can you lend me some money?
	I need a hundred for a last minute flight. Can you help me out?
Infringement of safety and privacy	Help me recall my cell phone password.
	I highly recommend you install this free software.
	I have sent you the contract, please click the link to sign.
Dissemination of false statements and information	There has been an emergency, all residents must evacuate immediately.
	A blood test for coronavirus costs three thousand dollars.
	Cocaine is a cure for COVID 19.
Bypass voice authentication	My voice is my password.
	My bank account is secured by my voiceprint.

基于上述现实威胁场景，本研究系统梳理并构建了真实世界中的典型语音样本库，为后续的技术对抗与防御策略研究提供实验依据。部分例句如表 2-1 所示。

本研究对攻击者能力作出如下设定：攻击者为第三方实体，无法通过物理接触获取目标用户的语音样本（如直接录制语音），其数据收集范围限于社交媒体、公开网站及视频流平台等公共域资源。攻击者具备中等计算资源，可运行现有语音合成工具或基于公开语音数据训练新模型（支持从头构建或模型微调）。参考近期 DeepFake 音频领域的研究，假定攻击者使用当前最先进的合成器，基于受害者语音样本实施零样本语音合成（即无需额外训练数据的合成技术）。

2.1.2.2 系统防御目标

在网络环境中，用户期望安全地分享语音音频，避免因内容公开导致声音特征被恶意采集，进而用于 DeepFake 语音合成攻击。为此，用户选择在音频发布前采用 SonicGuard 系统进行预处理。该系统基于对抗优化算法，通过向原始音频添加不可感知的特征扰动，重构声音信号的关键声学参数。经处理后的音频，不仅能有效规避恶意语音克隆，还能使合成音频无法通过常规语音识别及身份验证系统的检测。本作品基于以下核心假设展开：用户与 SonicGuard 系统均无法预先掌握攻击者所使用的具体语音合成模型，这一前提条件将直接影响后续技术方案的设计与实现。

SonicGuard 以最大限度降低原始音频内容损耗为前提，秉持为用户提供高效保护的核心设计理念。该系统的核心目标聚焦于两个关键维度：一方面，确保恶意合成的语音在听觉层面与用户真实声音存在显著差异；另一方面，使添加的扰动具备高度隐蔽性，在人类听觉感知中完全不可察觉，同时维持处理后语音自然流畅的听感，避免出现失真或异常现象。围绕上述目标，SonicGuard 构建起核心技术架构，通过创新算法设计与参数优化，实现安全性与音质的动态平衡。

2.2 系统设计思路及其原理

在语音合成系统的安全防护领域，说话人嵌入作为声纹特征的高维表征，其独特的空间分布特性对语音标识具有决定性影响。SonicGuard 系统的核心设计理念正是基于对这一特性的深入理解，通过向原始音频样本中精心构造特定的扰动模式，实现对嵌入空间表征的有效干扰。这种干扰的本质是在保持音频信号基本结构的前提下，针对性地破坏说话人嵌入的判别性特征，从而达到保护说话人身份信息的目的。

从技术实现的角度来看，虽然简单地注入高量级噪声确实能够显著改变说话人嵌入的空

间位置，但这种粗暴的干扰方式会不可避免地导致原始音频信号的严重失真。这种失真不仅会影响语音的可懂度，还会破坏语音的自然度和流畅性，使得处理后的音频在实际应用中失去实用价值。因此，如何在确保强保护效果的同时维持良好的音频质量，就成为系统设计中需要解决的关键问题。这个问题的复杂性在于，保护强度和音频质量往往呈现出此消彼长的对立关系，需要在两者之间找到最佳的平衡点。

2.2.1 系统优化框架

为了系统地解决这一复杂的声音对抗样本优化难题，构建了一个具有多重约束条件的对抗优化框架。该框架的核心思想在于将保护效果和音频质量这两个相互制约又同等关键的性能指标同时纳入优化目标函数，通过建立精确的数学建模方式，从多个维度量化它们之间的动态平衡关系。在这个创新性的优化框架中，不仅需要重点考虑对抗性扰动对说话人嵌入特征的干扰程度（即身份隐藏效果），还需要通过严格的数学约束条件来控制扰动对原始音频信号的时频域改变幅度（即信号保真度）。

该框架中所使用的关键变量定义如下表 2-2 所示。

表 2-2 变量定义

变量/函数名	说明
$\mathbf{x}_U$	用户 $\mathcal{S}_U$ 的原始语音音频
$\delta_{\mathbf{x}_U}$	由 <i>SonicGuard</i> 生成的扰动
$g(\mathbf{x})$	编码器模型，用于从语音 $\mathbf{x}$ 中提取说话者嵌入
$G(t, \mathbf{x})$	语音合成生成模型，输入为文本 t 和语音 $\mathbf{x}$
$D(z, z')$	度量两个嵌入 z 和 z' 之间差异的距离函数
$M(\delta)$	度量扰动 δ 对人类感知的影响的函数
$H(\mathbf{x})$	人类感知函数，判断语音 $\mathbf{x}$ 的说话者身份
$SV(\mathbf{x})$	说话者验证系统，输入为语音 $\mathbf{x}$

SonicGuard 的目标是通过优化生成的 $\delta_{\mathbf{x}_U}$ ，最大化说话者嵌入的偏离，同时保证人类感知的变化尽可能的小。形式化目标可以表示如下：

$$\begin{aligned} & \underset{\delta_{\mathbf{x}_U}}{\text{maximize}} \quad D(g(\mathbf{x}_U + \delta_{\mathbf{x}_U}), g(\mathbf{x}_U)) - \alpha M(\delta_{\mathbf{x}_U}) \\ & \text{subject to} \quad H(\mathbf{x}_U) \approx H(\mathbf{x}_U + \delta_{\mathbf{x}_U}) \end{aligned}$$

$$H(G(t, \mathbf{x}_U)) \neq H(G(t, \mathbf{x}_U + \delta_{xU}))$$

$$SV(G(t, \mathbf{x}_U)) \neq SV(G(t, \mathbf{x}_U + \delta_{xU}))$$

其中 α 是一个正向超参数，用于平衡保护强度与扰动的不可感知性。

2.2.2 优化策略

在上述多约束对抗优化框架下，进一步提出了一系列优化策略。在核心的身份保护机制方面，创新性地设计了基于动态阈值的控制方法，通过引入改进的 ELU 激活函数构建损失函数，实现了对说话人嵌入偏离程度的精准调控：当嵌入偏差低于预设阈值时快速逼近目标，超过阈值时则通过平滑衰减避免过度失真，在保护效果与语音自然度之间取得最优平衡。为应对实际应用中攻击者模型未知的挑战，研究采用多编码器联合优化策略，精心选取了涵盖 VAE^[35]、LSTM^[36]、ResNet^[37]和 Transformer^[38]四种典型架构的声学特征提取器，通过加权融合不同层次和粒度的声学特征，显著提升了生成扰动在黑盒场景下的泛化能力。针对语音合成系统常见的片段级嵌入聚合特性，提出了基于贡献度评估的自适应加权算法，通过实时计算各语音片段的嵌入差异倒数作为优化权重，有效解决了传统整体优化导致的局部最优问题。在不可感知性优化方面，创造性地将心理声学模型引入对抗样本生成过程：基于等响度曲线建立频率敏感度映射，实现扰动能量的智能分配；结合时频掩蔽效应和动态信噪比调节，充分利用原始语音的掩蔽特性；最终构建了融合身份保护、频率惩罚和信噪比约束的多目标优化函数。

下面对这些优化方法进行逐一阐述。

2.2.2.1 控制阈值法

尽管如上述公式所示，最终目标是充分偏离说话人嵌入，但并非偏离越大效果越好。例如，在极端情况下，偏离后的嵌入值会增长到异常高的水平，导致语音合成完全失败（完全静默或纯哨音），这很容易引起攻击者的注意。因此，认为有必要对偏离幅度（即保护强度）进行合理控制。为实现这一目标，有两种实现机制：一种基于阈值，另一种基于其他说话人的现有嵌入。

本作品采用基于阈值方法^[24]（Threshold-based Approach）实现控制，具体实现为：设定一个距离阈值 $\mathcal{T}$ ，将原始说话人的嵌入向量推离其原始位置，使其在嵌入空间中远离原始说话人的特征区域，按此思路，构造了如下损失函数：

$$\mathcal{L}_{\text{identity}}(\delta) = \text{ELU}[\mathcal{T} - D(g(\mathbf{x}_U + \delta\mathbf{x}_U), g(\mathbf{x}_U)), \alpha]$$

其中：

$$\text{ELU}(x, \alpha) = \begin{cases} x, & \text{if } x > 0 \\ \alpha(e^x - 1), & \text{if } x \leq 0 \end{cases}$$

这种方法采用指数线性单元 ELU 来推动优化过程：当嵌入偏差低于预设阈值 $\mathcal{T}$ 时，ELU 函数会快速缩小该偏差与阈值 $\mathcal{T}$ 之间的差距；当嵌入偏差高于预设阈值 $\mathcal{T}$ 时，ELU 函数通过参数 α 严格控制超出范围的程度^[25]。相比于 ReLU 的负区间硬截断（易导致神经元死亡）、LReLU 的简单线性泄漏（表达能力有限）和 SReLU 的多段参数化设计（计算复杂且易过拟合）^[26]，ELU 通过平滑的指数负区间处理，在保持 ReLU 正区间线性高效的同时，显著改善了梯度连续性、缓解了神经元死亡问题，并通过负值饱和特性使激活均值接近零，从而减少分布偏移，提升深层网络的训练稳定性。各种激活函数的对比如图 2-2 所示。




图 2-2 激活函数对比

这种设计既避免了严格限制导致优化僵化，又防止偏差无限扩大，保持了一定的灵活性。

2.2.2.2 联合编码器法

在反假冒防御的实际应用场景中，系统面临着极具挑战性的对抗环境：攻击者可能采用各种未知架构的语音合成模型，且防御方无法通过黑盒查询等方式获取目标模型的内部信息。这种模型不可知性的设定，使得传统基于白盒假设的对抗攻击方法完全失效，也使得开发具有普适性的扰动生成技术变得异常困难。

深入分析语音合成系统的本质特征可以发现，尽管不同模型在架构设计和实现细节上存在差异，但其核心功能都是要从输入语音中提取说话人的关键声学特征。这些特征通常包括但不限于：基频轮廓、共振峰分布、韵律模式、发音习惯等深层次的声纹标识。正是这种功

能层面的一致性，为开发通用防御方法提供了理论基础。

基于这一洞见，本作品创新性地提出了“特征空间全覆盖”的设计理念。通过精心挑选四类具有代表性的声学编码器构建集成系统，如下表 2-3 所示。

表 2-3 编码器介绍

编码器	架构	嵌入向量长度	数据集/说话人数量
AdaIN	VAE	128	VCTK / 109
GE2E	LSTM	256	Custom / 18000
H/ASP	ResNet	512	VoxCeleb 2 / 6000
ViT	Transformer	1024	Proprietary / -

这些编码器不仅在模型架构上形成互补，其嵌入空间维度也从 128 维到 1024 维不等，确保了特征表达的多样性。在训练过程中，系统采用自适应加权机制动态整合各编码器的梯度反馈：对于扰动敏感的编码器赋予更高权重，而对扰动鲁棒的编码器则适当降低其影响。这种设计巧妙地模拟了不同攻击模型的特征提取行为，使生成的扰动能够覆盖更广泛的潜在特征空间。

这一优化本质上是对模型中的 $g(\mathbf{x})$ 这一黑盒函数实现更加精准的控制，以实现未知攻击模型的有效防御。

2.2.2.3 加权分段损失法

现有语音合成器常常通过组合多个音频片段的局部嵌入生成最终的说话人嵌入，这就会产生一种现象：某些片段的次优嵌入会被其他已最优的片段抵消，导致整体嵌入陷入局部最优，难以进一步优化，进而导致了直接计算用户和目标嵌入的整体距离作为优化目标的效果十分不佳。

为了解决这个问题，采用了加权分段损失自适应法，根据每个音频片段的贡献动态分配权重，优先优化表现差的片段，自适应权重设计如下：

$$w_i = \frac{[d(g(\mathbf{x}_U^i + \delta^i), g(\mathbf{x}_U^i)) + \epsilon]^{-1}}{\sum_{k=1}^K [d(g(\mathbf{x}_U^k + \delta^k), g(\mathbf{x}_U^k)) + \epsilon]^{-1}}$$

w_i 表示第 i 段音频的权重， K 是分割总段数， $d(\mathbf{e}_1, \mathbf{e}_2)$ 函数用于计算两个二维嵌入的距离，以其倒数反映其贡献作为权重，倒数越大反映其表现越差，公式如下：

$$d(\mathbf{e}_1, \mathbf{e}_2) = \sum_{i=1}^n \left| \sum_{j=1}^m (\mathbf{e}_{i,j}^{(1)} - \mathbf{e}_{i,j}^{(2)}) \right|$$

这样，将原本给出的 $\mathcal{L}_{\text{identity}}(\delta)$ 更新为以下公式：

$$\mathcal{L}_{\text{identity}}(\delta) = \sum_{k=1}^K \mathcal{W}_k \cdot \text{ELU} \left[\mathcal{T} - D(g(\mathbf{x}_U^k + \delta \mathbf{x}_U^k), g(\mathbf{x}_U^k)), a \right]$$

通过如上处理，有效打破了传统方法容易陷入的局部最优困境，使嵌入空间探索更加充分；增强了嵌入调整的灵活性，不同质量的片段都能获得适度的优化关注，显著提升了产生扰动的鲁棒性。

2.2.2.4 频率惩罚机制

频率惩罚机制是一种基于人耳听觉特性设计的扰动优化方法，旨在通过利用人类听觉系统对不同频率声音的敏感度差异，增强语音对抗样本的不可感知性。该方法的核心思想是：在生成对抗扰动时，根据不同频段对人耳感知的影响程度施加动态惩罚权重，使得最终的扰动信号在关键频段（如人耳敏感的中高频范围）保持更低的能量，从而提升对抗样本的隐蔽性^[27]。

该机制的核心思想源自等响度曲线（Equal-Loudness Contour，又称 Fletcher-Munson 曲线或 ISO 226 标准），如下图 2-2 所示。这是一个描述人耳对不同频率声音感知响度的关键模型，反映了人类听觉系统对声音频率的非线性敏感度。它通过实验测量不同频率下人耳感知相同响度所需的声压级，并绘制成一组曲线，每条曲线代表一个响度级。它揭示了人耳听觉系统的重要特征：响度依赖性，随着整体响度的提高，这种频率敏感度的差异会逐渐减小，即在较高声压级时，人耳对不同频率的响应趋于平缓。此外，等响度曲线还表现出临界频带特性，即人耳会将频谱划分为若干临界频带，每个频带内的声音会相互影响。这些听觉特性为频率惩罚机制提供了理论基础，通过将等响度曲线的敏感度特征量化为频率权重，使得生成的语音扰动在人耳敏感频段保持更低的能量，从而在不影响攻击效果的前提下显著提升对抗样本的不可感知性。




图 2-2 等响度曲线

具体实现中，首先将不同频段的声压级（SPL）线性映射为不可感知性增益（取值范围 1 到 0，增益越高表示该频段扰动越难被察觉），绘制结果如下图 2-3 所示。其中，人耳较不敏感的高频段（如 8kHz 以上）会被赋予接近 1 的高增益值，允许注入更多扰动能量；而对中频敏感区域（1-3kHz）则严格限制增益在较低水平。这种差异化的分配策略既确保了关键频段的语音质量，又能在听觉迟钝区域充分保留对抗扰动的有效性。同时，系统还会根据语音内容的实时频谱特征动态调整各频段增益，进一步优化隐蔽性。通过这种精细的频域控制，实现了对抗扰动与语音自然度的最佳平衡。




图 2-3 频段增益值曲线

如此，通过加权求和计算频率惩罚项，使得优化过程倾向于在难感知频段插入更多扰动：

$$\mathcal{L}_{\text{percept}}(\delta) = \sum_{k=1}^K W(f_k) \cdot |\hat{\delta}(f_k)|$$

此外，考虑原始语音的上下文作用（如响亮语音可掩盖更多扰动），尝试利用听觉中的掩蔽效应（Masking Effect）：人的耳朵只对最明显的声音反应敏感，而对于不明显的声音，

反应则较不为敏感^[28]。一个声音的闻阈值由于另一个声音的出现而提高的效应。前者称为掩蔽音，后者称为被掩蔽声。纯音的掩蔽基本符合以下几个规律：低音容易掩蔽高音，高音较难掩蔽低音；频率相近的纯音容易互相掩蔽；提高掩蔽声的声压级时，掩蔽阈会提高，而且被掩蔽的频率范围会扩展。掩蔽效应示意图如图 2-4 所示：




图 2-4 掩蔽效应示意图

由此，引入了信噪比（SNR）作为辅助指标，反映有用信号的功率与背景噪声功率的比值，充分利用响亮语音的掩蔽效应进一步隐藏扰动。

$$\text{SNR(dB)} = 10\log_{10} \left(\frac{P_{\text{signal}}}{P_{\text{noise}}} \right)$$

同时，信噪比也是一个计算效率极高的测量方法，有利于快速优化，在短时间内获得最佳结果，具有可行性。不同范围信噪比对比效果如表 2-4 所示。

表 2-4 信噪比对比效果

信噪比(SNR)	听觉效果	应用场景
>50 dB	几乎无噪声，专业录音室品质	高保真音乐、影视原声
30~50 dB	轻微噪声，不影响清晰度	高质量通话、播客录音
10~30 dB	明显噪声，需降噪处理	电话语音、会议录音
<10 dB	噪声淹没信号，难以听清内容	嘈杂环境下的语音采集

最终，通过多目标联合优化框架，实现了对抗扰动 δ 的生成优化。具体而言，该框架将三个关键指标进行协同优化：首先，身份损失函数 $\mathcal{L}_{\text{identity}}(\delta)$ 确保生成的对抗扰动能够有效干扰语音合成系统，使其无法正确识别说话人身份特征；其次，感知损失函数 $\mathcal{L}_{\text{percept}}(\delta)$ 通过模拟人类听觉系统的感知特性，约束扰动的可察觉性，使其在时频域上保持隐蔽；最后，信

噪比 SNR 指标作为量化约束条件，进一步保证添加扰动后的语音信号与原始语音在能量层面上保持高度一致。这三个优化目标通过自适应加权机制进行平衡，在对抗效果和听觉隐蔽性之间取得最优权衡，从而生成既能可靠地误导语音合成系统，又能在人耳听感上近乎无声的对抗样本。实验表明，这种联合优化策略显著提高了对抗攻击的鲁棒性和隐蔽性，为语音合成系统的安全性研究提供了新的技术途径。

2.3 系统实现

2.3.1 系统架构

本作品的整体架构如图 2-5 所示，主要由前端交互、后端控制和核心处理三个模块构成，共同构建了一个完整的基于对抗扰动的语音隐私主动防御系统。各模块通过云服务器和数据接口协同工作，确保流程自动化与高效运行。

用户首先通过 PC 端远程访问**前端交互模块**提供的 Web 平台，完成注册登录后，可利用平台功能进行音频录制与上传、提交测试请求以及查询历史记录。在用户上传原始音频或实时录音并提交测试请求后，数据经由云端传输至**后端控制模块**。后端模块执行用户身份验证，将音频数据上传至服务器并接入系统主流程，负责管理注册登录验证、音频数据处理、任务调度等，并协调后续的扰动生成与测试过程，确保数据流正确无误且任务有序执行。进入**核心处理模块**后，系统首先调用格式统一子模块，将用户上传的音频统一转换为符合模型输入要求的格式：16-bit 单声道 PCM WAV 文件，采样率 16kHz，比特率 256kbps。格式统一后的音频随即进入对抗扰动生成子模块，该模块基于特定算法添加微小扰动，旨在最大限度扰乱说话人嵌入特征，同时力求使扰动在人类听觉范围内不可察觉，从而实现有效的隐私保护。扰动音频生成后，系统调用科大讯飞 API 检测原始音频和处理后音频的相似度，判断防伪是否成功。最后，处理结果通过后端反馈至前端 Web 平台，用户可在此查看分析结果，包括扰动是否成功、防御效果强度等信息。通过上述模块的紧密协作，系统实现了从音频上传、扰动生成、效果评估到结果反馈的完整闭环，具备良好的可拓展性和使用性，适用于音频隐私保护及抗识别技术研究场景。




图 2-5 系统架构

2.3.2 前端实现

本作品前端部分基于 Vue 框架进行开发，使用 vite 工具构建项目。采用模块化和组件化设计，提升了代码的可读性和可维护性。前端界面采用响应式设计，适应不同设备，确保在不同终端设备上均能提供良好的用户体验。下面将对前端界面进行详细介绍：

1、系统介绍与导航界面

用户打开网址首先是以未登录的状态进入首页，如图2-6所示。页面右侧提供有交互效果的旋转唱片，提升趣味性，左侧则简明扼要地说明了系统功能与特点。点击“快速录制”、“安全防伪”、“实时处理”和“开始体验”，将跳转到音频处理界面；点击“一键检测”，会跳转到音频检测界面；点击“了解更多”，将跳转至“关于我们”界面，如图2-7所示。用户可以通过该界面显示信息获取开发人员的联系方式，及时实现沟通。此外，如果用户在未登录状态下使用了“一键音频处理”和“音频真伪测试”等涉及到个人账户的功能，系统会自动跳转至登录页面。用户需成功登录后方可返回主界面并使用相关功能。




图 2-6 系统首页




图 2-7 “关于我们”界面

2、注册与登录

系统通过调用后端接口处理用户输入的个人信息，完成注册与登录验证，并在验证成功后执行路由跳转。如图 2-8 注册界面，图 2-9 登录界面，用户可以输入账号、密码进行注册或登录。登录验证成功后，系统会自动跳转到音频处理界面。用户登录界面采用了渐变色标题和简洁的表单设计，提高视觉吸引力；注册界面则增设了邮箱验证和图形验证码功能，用户输入信息需在前端本地验证通过后才提交至后端，有效防范恶意注册行为。




图 2-8 注册界面




图 2-9 登录界面

3、音频处理界面

音频处理界面作为系统的核心功能区域，为用户提供多样化的音频输入选项和强大的防伪处理功能，如图 2-10 音频处理界面所示。该界面支持用户上传各种常见音频格式（MP3、WAV、M4A 等），同时基于 Web Audio API 和 MediaRecorder API 技术，实现了便携的在线录音功能，并且在录制过程中实时显示录音时长，便于用户掌控。用户可以随时更换自己选择的音频，界面会通过高亮标识当前选择的输入方式，提供了良好的操作直观性和用户体验。

用户点击“一键防伪处理”后，系统将执行处理流程并返回关键结果：处理后的音频、模拟攻击者分别利用原始音频和处理后音频生成的伪造音频样本，以及直观展示音频变化的频谱对比图和防御效果评分，如图 2-11 频谱图。上述输出清晰展示了防伪处理效果，便于用户评估。此外，用户还可以点击快捷下载按钮，将处理结果保存至本地。




图 2-10 音频处理界面




图 2-11 频谱展示

4、音频测试界面

为了满足用户评估其他处理方法防伪效果的需求，系统提供了专门的音频测试界面，如图 2-12 所示。该界面清晰划分原始音频与待测音频（即用户使用其他方法处理后的音频）的上传区域，支持用户拖放文件至指定区域完成上传。系统自动检测上传文件格式，通过直观的视觉反馈实时告知用户文件上传状态。用户点击按钮即可启动专业的音频真伪对比分析，通过可视化仪表盘直观展示真实性评分和检测的通过状态。系统根据检测结果生成针对性建

议，帮助用户理解当前防伪效果并提供改进方向。




图 2-12 音频测试界面




图 2-13 个人界面

5、个人信息与历史记录管理

系统通过调用后端接口获取数据，并在个人信息界面集中展示与管理用户资料及操作历史，如图 2-13 所示。用户可以在该界面修改自己用户名、电子邮箱、个性签名，以及上传/更换个人头像。更新后的信息将实时同步在系统导航栏中。个人界面还提供了完善的历史记录管理功能，包括音频处理历史和音频测试历史的查询、筛选、比较和导出，方便用户追踪历史操作和结果比对。

2.3.3 后端实现

本作品后端采用 Python 语言实现，主要应用 Django 框架完成代码开发。在结构方面，本作品采用的是前后端分离的方式进行交互。后端采用 RESTful API 设计，使用 HTTP 通信协议区分操作类型，返回 JSON 格式数据实现和前端的交互，通过 django-cors-headers 中间件配置 CORS 实现跨域处理。后端路由与对应的绑定函数如表 2-5、表 2-6 和表 2-7 所示。

表 2-5 用户认证与管理

路由	视图类/函数	功能描述
/auth/register/	UserRegistrationView	用户注册接口
/auth/login/	LoginView	用户登录接口
/user/profile/	UserProfileView	获取或更新用户个人信息
/upload/avatar/	AvatarUploadView	用户头像上传接口

表 2-6 音频处理

路由	视图类/函数	功能描述
/audio/process/	AudioProcessView	音频文件上传与处理主接口
/audio/test/verify/	AudioScoreView	音频测试验证接口
/audio/history/process/	ProcessHistoryView	获取音频处理历史记录列表
/audio/history/test/	TestHistoryView	获取音频测试历史记录列表
/audio/history/<int:record_id>	AudioHistoryDetailView	单条处理历史记录详情
/audio/test/<int:record_id>	AudioTestHistoryDetailView	单条测试历史记录详情

表 2-7 API 调用模块

路由	视图类/函数	功能描述
/xfyun/<str:api_name>/	XFYunAPIView	科大讯飞 API 代理接口

对于登陆后的页面的访问权限，服务端不保存客户端会话状态，而使用 Token 认证机制来进行用户的身份验证。本作品中使用的 Token 认证方案是 Token 认证方法是 JSON Web Token（JWT）的变体实现，具体为基于 Django REST Framework（DRF）的 Simple JWT 库提供的 Refresh-Token 方案，利用 HMAC-SHA256 签名算法保证 Token 的有效性。

在音频预处理模块，后端首先接收用户上传的音频文件，通过文件扩展名识别其格式（如 MP3、WAV 等），若非 WAV 格式则使用 pydub 音频处理库，利用 ffmpeg 工具将其转换为标准的 WAV 格式，转换过程完全在内存中进行以避免临时文件存储，同时保留原始文件名

仅将拓展名变更为.wav。

在异常处理模块，本作品采用符合 RFC 7807 的 HTTP API 错误处理标准中的三级错误分析法，在出现错误时返回错误类型、错误描述和对应的 HTTP 状态码、针对错误的详细说明，同时为实现对系统中每一次客户端请求的唯一标识与全链路追踪，系统为每个 HTTP 请求分配一个全局唯一的请求标识符。最终将异常的返回封装成 `handle_error` 函数在每一个板块进行调用。

后端采用 SQLite 数据库对用户信息和上传的音频记录进行存储，同时对数据库中用户密码等敏感字段进行加密，保证数据的安全性和稳定性。用户提供注册信息完成注册，后端将用户的用户名、密码、邮箱、登陆时间等存入数据库，并为每个用户分配唯一的 ID 并返回含身份证明的 Token。登陆后用户可以选择是进行音频防伪处理还是进行音频防伪检测。如果进行音频防伪处理，需要用户上传音频，后端将音频保存到数据库中，将音频转成标准的 WAV 格式文件，并调用音频处理程序进行处理，处理之后将原音频和处理后的音频调用科大讯飞的 API 检测两个音频的相似度，判断防伪是否成功，将最后的测试结果保存到数据库；如果是音频防伪检测，用户上传处理前和处理后的两个音频，并将这两个音频保存到数据库，再直接调用科大讯飞 API 进行防伪测试即可，将最后测试结果保存到数据库。在历史信息模块，用户可以查看自己的历史处理记录，并看到得分。

根据上述功能要求完成数据库 E-R 图的构建，如图 2-14 所示。由图可知，数据库创建了四张表，用于存储用户信息、处理前的音频信息、处理后的音频信息以及测试音频信息，**用户信息表**包括用于注册登录操作的用户名、邮箱和密码，以及用于个人信息的展示页面的个性签名和头像路径；**处理前的音频信息表**包括文件路径和文件名，用于对上传文件进行记录，方便后续查找，也包括文件大小、文件格式和音频时长，用于记录文件特性，以及上传时间和关联用户 ID，用于找到上传该音频的用户，在该用户的历史记录页面展现此音频；**处理后的音频信息表**包括文件路径和文件名，用于记录处理后的文件，方便后续查找，也包括处理时刻和测评评分，用于表示该音频的属性，同时关联原音频，用于建立处理链路，方便后续评测时的调用等情况；**测试音频信息表**包括原始音频名称、用户名和分数，用于在历史记录中呈现该用户在音频测试板块的记录。




图 2-14 数据库 ER 图

下面对后端提供的服务进行详细的介绍：

1、注册与登录

用户在访问平台前需要完成注册。新用户注册时，前端将用户名、密码、邮箱等参数传递至后端，后端首先验证参数的合法性，并确保用户名在数据库中唯一且密码结构符合要求。验证通过后，系统自动生成一个递增的新用户 ID，并使用 Django 内置的 PBKDF2+HMAC+SHA256 加密算法对密码进行安全加密存储。同时，后端生成一个认证 Token 返回给用户用于后续身份验证。当用户登录时，前端提交用户名和密码至后端。后端通过比对数据库中的加密记录进行身份核验：若匹配成功，则签发新的 Token 授权访问；若匹配失败，则拒绝登录请求。

2、音频上传、处理与检测

在音频上传模块，首先会根据 Token 检测用户的合法性，如果合法，前端传输音频文件至后端。后端首先执行基础校验，确认文件非空且为有效音频类型。若校验成功，则根据用户选择进入处理或检测流程；否则，会返回错误信息。在音频处理模块，后端首先根据

Token 检测用户的合法性，然后检查已上传音频是否为 WAV 格式，若非 WAV 格式则先将其转换为标准 WAV 文件。随后调用核心处理程序 `run.py` 生成对抗扰动音频，最终将处理后的文件关联存储至数据库。在音频检测模块，用户需上传原始音频与待测音频两个文件，后端统一将双音频转换为 MP3 格式，以满足第三方 API 的要求。随后调用科大讯飞音频相似度 API，检测两个文件的差异性，获取 API 返回的相似度分数之后，后端将该分数返回前端展示，并将检测结果存入数据库。

3、历史记录获取服务

该服务首先检测用户 Token 的合法性。验证通过后，后端利用用户的 ID，找到用户对应的历史记录。这个历史记录分为两个部分：音频处理的历史记录和音频检测的历史记录。对于音频处理的记录，查询该用户所有已处理的原始音频文件，并返回对应处理时间、防御评分等关键信息至前端；对于音频检测的记录，检索该用户执行的音频检测任务，从数据库中提取关联的测试记录并返回前端展示。

3 作品测试与分析

3.1 测试方案

本作品从以下两个维度开展测试，确保功能与性能符合设计预期。

3.1.1 Web 交互系统功能性测试

模拟用户在 Web 端的全流程操作，包括音频上传、结果下载等功能模块的交互操作，检查界面响应速度、功能完整性及操作流畅性，同时验证系统在不同浏览器、网络环境下的兼容性与稳定性。

1、功能性测试：进行全流程操作。模拟用户从音频上传 → 后台处理 → 结果生成 → 下载结果的完整路径，验证数据一致性及状态同步。模拟异常场景，上传中多次点击按钮，检查重复请求拦截。操作中等待超时，恢复后是否需重新登录并保留数据。

2、性能测试：通过自动化检测工具测试页面加载时间、操作响应延迟、API 接口响应等指标，测试界面响应速度。

3.1.2 系统防御功能有效性测试

1、音频听感一致性测试：通过专业音频分析工具与人工主观评测相结合的方式，对比原始音频与经 SonicGuard 处理后的音频，评估两者在音色、音调、节奏等听觉特征上的相似程度，验证处理过程对原始音频自然听感的保持能力。

2、合成音频差异性测试：将原始音频与处理后音频分别输入主流语音合成模型，对生成的合成音频进听感对比。重点检测处理后音频是否显著降低合成音频与用户真实声音的相似度，以量化 SonicGuard 对恶意合成攻击的防御效果。

3、防伪认证有效性测试：将合成音频提交至第三方权威语音身份验证系统，依据系统输出的认证结果与防伪评分，评估 SonicGuard 处理后的音频在实际应用场景中抵御 DeepFake 攻击的能力，验证其防伪机制的可靠性。

3.2 测试环境

为了确保系统运行的稳定性和功能完善性，本作品对实验平台的硬件配置、系统软件环境以及模块级功能库进行了系统整理，如表 3-1、表 3-2 和表 3-3 所示。

表 3-1 硬件配置

设备类型	设备参数
操作系统	Ubuntu 20.04.5 LTS
内核	Linux 5.15.0-53-generic x86_64
CPU	Intel® Xeon® CPU E5-2680 v4 @ 2.40GHz × 28
GPU	NVIDIA Quadro RTX 5000 × 2

表 3-2 软件环境

类型	版本
Python	3.7.16
NumPy	1.21.5
SciPy	1.7.3
Pandas	1.3.5
OpenCV	4.7.0.72
CUDA	11.6
cuDNN	8.3.2

表 3-3 模块依赖

类型	版本
PyTorch	1.13.1
TorchVision	0.14.1
TorchAudio	0.13.1
TensorFlow	1.13.1
Librosa	0.8.0
SoundFile	0.12.1
PyDub	0.25.1
Resampy	0.3.1
WebRTC VAD	2.0.10
SpeechBrain	0.5.14
Transformers	4.19.0
SentencePiece	0.1.98
NLTK	3.8.1
Jieba	0.42.1
Text-Unidecode	1.3

3.3 数据集与评价标准

为支撑基于 VAE、LSTM、ResNet 和 Transformer 四种架构的多编码器联合优化策略，本作品选取了多个语音数据集用于训练不同架构的声学编码器，以实现对话话人特征空间的全面建模。所使用的数据集包括 LibriSpeech^[29]、LibriTTS^[30]和 VoxCeleb^[31]系列数据集，具备良好的语音质量、丰富的说话人数量和语言风格，广泛应用于语音建模任务。本作品中 LibriSpeech 与 LibriTTS 提供标准语音识别与合成场景下的多说话人语音样本，适用于训练 VAE、LSTM 等架构的编码器；VoxCeleb 系列数据集则广泛用于训练说话人识别模型以及生成说话人嵌入特征，为 ResNet 和 Transformer 等深层架构的编码器提供了强有力的训练支持。

3.3.1 LibriSpeech 数据集

语音识别与合成系统的研究对高质量、标注准确的语音数据提出了严格要求。相较于噪声复杂的说话人识别场景，语音识别更关注语音内容本身的清晰度与准确度。LibriSpeech 是一个经典的开源英文语音语料库，具有语音质量高、语料结构规范、文本对齐准确等优点，广泛应用于语音识别、语音合成、语音增强等研究任务。该数据集基于 LibriVox^[32] 项目的有声读物构建，内容涵盖多种公开出版的英文文学作品，语音由志愿者清晰朗读，录音在较为理想的环境中完成，信噪比高，适合用于建模或评估语音系统在“近理想环境”下的性能表现。整体语音时长超过 1000 小时，语音格式统一为 16 kHz 单声道 WAV。数据按照不同说话人组织，发音内容由人工标注并提供精确文本转录，确保了语音与文本之间的高度一致性。数据集的构建过程中，采用了先进的语音识别技术，对原始音频进行了预处理和标准化，以确保数据的质量和一致性。对 LibriSpeech 数据集的详细描述如表 3-4 所示。

表 3-4 LibriSpeech 数据集

子集名称	样本数量	描述
dec-clean	2703	干净语音的开发集，用于验证模型
dev-other	2864	有杂音的开发集
test-clean	2620	干净语音的测试集，用于标准评估
test-other	2939	有杂音的测试集
train-clean-100	28539	100 小时干净语音，用于训练
train-clean-360	104014	360 小时干净语音，用于增强训练
train-other-500	148688	500 小时语音质量较差的数据，用于训练时增加鲁棒性

在本作品中，LibriSpeech 数据集作为主要训练语料之一，承担了声纹编码器模型的训练任务。实验使用了 LibriSpeech 的多个子集，以提供不同质量和多样性的英语语音样本。这些子集涵盖了大量具有明确说话人标注的高质量语音样本，支持模型在多说话人场景下学习稳定且区分性强的语音特征表示。

3.3.2 LibriTTS 数据集

LibriTTS 是在 LibriSpeech 数据集基础上构建的一个面向语音任务的大规模语音语料库，专为多说话人语音合成和语音生成研究设计。该数据集延续了 LibriSpeech 的开放性与高质量标准，使用相同来源的有声读物语音材料，但在构建过程中进行了更适配语音合成任务的预处理，例如去除背景噪音、重采样、文本正则化和音频截断等。LibriTTS 的音频采样率为 24kHz，较 LibriSpeech 更高，能更好地保留语音细节；同时提供了对齐良好的文本标注和分段语音文件，支持逐句生成的建模需求。整个数据集总时长约为 585 小时，以说话人和子集划分，支持多说话人建模和个性化语音生成研究。LibriTTS 被广泛应用于训练和评估 TTS 模型，特别使用于研究语音生成的自然度、语音清晰度与说话人一致性等性能指标。对 LibriTTS 数据集的详细描述如表 3-5 所示。

表 3-5 LibriTTS 数据集

子集名称	样本数量	描述
dec-clean	5736	干净语音的开发集，用于验证模型表现
dev-other	4613	有一定噪音的开发集
test-clean	4837	干净语音的测试集，用于标准评估
test-other	5120	有杂音的测试集，用于模拟非理想合成场景
train-clean-100	33236	100 小时干净语音，用于基本训练
train-clean-360	116500	360 小时干净语音，用于增强训练
train-other-500	205044	500 小时语音质量较差的数据，用于训练时增加鲁棒性

在本作品中，LibriTTS 数据集被用作语音合成任务的数据来源，为模型训练提供了多样化的高质量语音样本，使系统具备更强的语音生成能力与对多说话人语音风格的泛化能力。

3.3.3 VoxCeleb

VoxCeleb 是一个用于说话人识别与验证任务的开源英语语音数据集，广泛应用于声纹识别、说话人分类、语音表征学习等研究领域。该数据集由英国牛津大学开发，主要通过自动化流程从 YouTube 视频中提取高质量语音片段，结合人脸识别与音视频同步技术，确保语音

与说话人身份的对应关系准确可靠。VoxCeleb 包含多个版本，其中 VoxCeleb1 提供了较小规模但结构清晰的数据集，适合模型初步训练与测试；VoxCeleb2 规模更大，涵盖更多样化的说话人、口音与场景，适合大规模建模任务。所有语音数据为 16kHz 单声道 WAV 格式，去除了背景音乐与明显杂音，具有较高信噪比。数据集按说话人组织，每位说话人包含多个自然语境下的语音样本，广泛用于端到端声纹系统的训练、微调与评估。对 VoxCeleb 数据集的详细描述如表 3-6 所示。

表 3-6 VoxCeleb 数据集

数据集名称	说话人数	描述
VoxCeleb1	1251	高质量语音，适合说话人识别与验证的基础任务
VoxCeleb2-dev	5994	涵盖更多口音与环境，适合深层模型训练
VoxCeleb2-test	118	用于验证在不同语境和说话人下的识别能力

在本作品中，VoxCeleb 数据集主要用于训练和评估声纹编码器与说话人判别模块，增强模型对多说话人环境下的鲁棒性与泛化能力。

3.3.4 评价指标

1、平均意见得分（Mean Opinion Score, MOS）^[33]，是一种广泛应用于音频、视频等多媒体质量评估的主观评价方法，在音频领域常被用于衡量语音质量和听感体验。在上述系统测试中，MOS 可作为评估音频处理效果的关键指标。

在“音频听感一致性测试”中，MOS 能直观反映原始音频与经 SonicGuard 处理后音频的听感差异。测试时，会邀请一定数量具有专业音频感知能力或普通用户群体作为测试者，让他们分别收听原始音频和处理后的音频，并按照 5 分制量表进行打分。5 分代表“音质极佳，听感与原始音频几乎无差别”；4 分为“音质良好，存在轻微差异但不影响整体体验”；3 分意味着“音质一般，差异较为明显”；2 分为“音质较差，听感有显著缺陷”；1 分则表示“音质极差，难以接受”。将所有测试者的打分进行平均，得到的 MOS 值越接近 5，说明处理后的音频在听感上越接近原始音频，SonicGuard 系统对音频自然听感的保持能力越强。

2、感知说话人差异（Perceptual Speaker Dissimilarity, PSD）^[34]是衡量两个语音样本在说话人身份感知层面的差异程度，强调从人类听觉主观体验出发，量化“声音是否属于同一个人”的感知差异。

在“合成音频差异性测试”中，PSD 能直观反映 SonicGuard 处理前后音频，经过语音合成后，在说话人身份感知层面的差异，为评估 SonicGuard 系统的防伪效果提供关键依据。测试时，邀请大量测试者对基于原始音频和处理后音频合成的新音频进行主观评分，使用 5 分制量表，1 分为差异最小，5 分为差异最大，并将评分结果与 PSD 客观计算值进行拟合分析。若 PSD 得分较高，表明与原说话人语音形成显著区分，有效降低了合成音频被误认为真实语音的风险。

3、声纹识别得分（Voiceprint Recognition Score），通过提取说话人声音特征和说话内容信息，自动核验说话人身份，输出相似度得分。

科大讯飞声纹识别 API 依托讯飞领先的语音识别和声纹建模技术，具有高准确性。

在“防伪认证有效性测试”中，通过调用科大讯飞的声纹识别 API，进行 1：1 比对的声纹认证。将原音频和经过 SonicGuard 处理后的音频进行声纹特征的比对，输出相似度得分，建议的参考得分范围为 0-0.4，说话人声纹信息不相似，判断不为同一个人，表明 SonicGuard 对音频的主动防御功能有效。

4、Web 性能指标

表 3-7 Web 性能参考指标

指标	定义
页面加载时间	从用户发起页面请求到浏览器完全渲染内容的总耗时
操作响应延迟	用户触发操作（如点击按钮）到界面反馈的时间，影响交互流畅度
API 接口响应时间	从 API 请求发出到接收完整响应的耗时
内存占用峰值	程序在运行过程中达到的最大内存使用量

3.4 结果展示和分析

3.4.1 Web 交互系统性能

本作品通过多维度测试验证了其在**音频防伪处理**与**音频防伪测试**两个核心模块的功能有效性与交互性能表现。

在**音频防伪处理模块**中，用户点击选择文件按钮选择本地待处理的音频，系统自动完成对抗扰动生成与可视化展示。实测页面加载时间约为 3.1 分钟，用户点击交互相应延迟为 387.03ms，API 接口响应时间为 3.1 分钟，处理期间内存峰值约为 12MB，系统整体表现稳定。处理完成后系统同步展示四段关键样本：原始音频、扰动处理音频、模拟原始音频受 TTS 攻

击的伪造样本、模拟处理后音频受 TTS 攻击的伪造样本，如图 3-1 所示。




图 3-1 音频防伪处理

通过原始音频和处理后音频的防伪评分，评估扰动的有效性：经过扰动处理，处理后音频与原始音频防伪评分为 81/100，系统提示“音频处理质量优秀，很好地满足防伪要求”，表明对抗扰动显著提升了音频的抗伪造能力。此外用户还可以通过播放模拟攻击者分别根据原始音频、处理后的音频进行 TTS 攻击生成的音频，主观感受防伪效果。音频防伪结果如图 3-2 所示。



图 3-2 音频防伪结果

进行防伪测试后，用户可下载处理后的音频，在下载任务弹窗中选择下载地址和文件名，将文件保存到本地，满足用户对音频防伪的需求，如图 3-3 所示。




图 3-3 防伪音频下载

在**音频防伪测试模块**，用户上传两段完全相同的音频进行测试，系统返回预期真实性评分 0/100（规则设定：<60 分表示音频高度相似未达防伪效果），并生成提示“您提供的两个音频极为相似，建议使用我们处理系统进行音频处理以提高防伪性能”。结果精准体现了系统评分机制的判别能力，0分表明音频无差异性，与用户输入完全吻合，且触发防伪处理引导功能，体现检测模块的严谨性，如图 3-4 所示。该模块操作响应延迟为 421.13ms，API 响应时间为 893.34ms，页面整体检测耗时约 1.32 秒，内存占用峰值仅 64.5KB，系统交互流畅。



图 3-4 音频防伪测试结果为不可信

然而，当用户上传原始音频和经过防伪处理的音频进行测试时，系统返回真实性评分 83/100，并生成提示“该音频区分度已较大，已经可以通过科大讯飞 API 的检测”，如图 3-5 所示。防伪测试结果与预期相符，体现了防伪处理的有效性与防伪测试的准确性。




图 3-5 音频防伪测试结果为可信

系统还提供历史记录管理功能，可追溯每一次音频处理的评分差异和波形对比支持文件导出与个性化命令，辅助用户整理与验证处理过程。以案例 `original_1750747140.mp3` 为例，页面同时呈现原始音频与处理后音频的波形对比和测试评分，用户可执行双轨播放比对或通过下载按钮导出文件（支持自定义路径与文件名），删除功能则确保数据管理灵活性，如图 3-6 示。此项操作页面加载时间约为 30.06ms，操作响应时间约为 0.87ms，API 响应时间约为 26.43ms，内存占用峰值为 322KB，各项指标表明系统具备良好的可追溯性与轻量级性能。




图 3-6 历史记录管理

为了评估系统在 Web 交互过程中的响应性能与资源占用情况，本作品对各核心模块的页面加载时间、操作响应延迟、API 接口响应时间及内存占用峰值进行了量化测试，测试指标结果汇总如表 3-8 所示。

表 3-8 Web 性能测试结果

操作	页面加载时间	操作响应时间	API 接口响应时间	内存占用峰值
音频防伪处理	3.1min	387.03ms	3.1min	12MB
音频防伪测试	1.32s	421.13ms	893.34ms	64.5KB
查询历史记录	30.06ms	0.87ms	26.43ms	322KB

本作品从多个维度对所设计的语音防伪系统进行了 Web 交互功能性评估。测试结果表明该系统在一下几个关键方面表现出色：

1、防伪效果显著：系统在音频防伪模块中对原始音频生成的对抗扰动有效增强了样本的抗伪造能力。实测显示，经过扰动处理，处理后音频与原始音频防伪评分为 81/100，验证了系统对 TTS 攻击具备实际防御能力。

2、检测机制可靠：用户上传两端完全相同音频时，系统准确输出真伪评分 0/100，结合防伪规则（<60 分为高度相似）和提示语句，引导用户使用防伪处理功能。而当用户上传原始音频和经过防伪处理后的音频时，系统准确输出真伪评分 83/100，结果显示音频防伪处理效果优秀，体现了系统评分逻辑的严密性与实际可用性。

3、用户交互友好：系统界面设计直观简洁，操作流程清晰，提示语句明显，用户可自由查看音频波形、评分结果与元数据信息。防伪评分与提示语句的结合设计有效降低使用门槛，适合不同背景的用户使用。

4、记录管理完整：系统支持用户个人记录归档管理，通过双规音频展示、评分变化对比、操作详情记录、音频导出与删除功能，实现了从音频处理、防伪检测到结果管理的闭环流程，便于用户追溯与管理历史操作。

5、系统维护便捷：系统基于前后端分离架构设计，具备良好的模块解耦特性，便于后期维护与功能升级，同时为引入新型检测算法和功能拓展提供了充足的灵活性与可持续发展空间。

6、响应性能优良：在多轮实际操作中，系统在音频上传、扰动生成、模型预测与检测反馈各环节均保持流畅体验。在音频防伪处理模块，尽管存在计算复杂度较高的对抗扰动生成过程，但页面整体加载时间较短，且内存占用峰值低，在保障防伪精度的同时实现了良好的交互体验。防伪测试模块的平均响应时间为秒数级，可满足用户在线检测的流畅性需求。

综上所述，本作品在音频防伪处理与防伪测试上具备良好的工程实现效果与实际部署能力，体现出较高的实用性、可拓展性与推广潜力，适合在多种语音安全应用场景中使用。

3.4.2 系统防御性能

(1) 客观相似度测评

SonicGuard 系统调用科大讯飞的声纹识别 API，选取了三个主流开源语音数据集——VoxCeleb、LibriTTS 和 LibriSpeech，各采样 50 条语音作为测试样本，总计 150 条，统一采用科大讯飞声纹识别接口进行评分。每条评分反映扰动音频与原始音频在声纹空间中的相似程度，评分越低，表示伪造音频被系统有效扰乱，其与原始声纹特征差异越大，防御效果越强。

测试结果如图 3-7 所示，VoxCeleb 数据集中得分主要集中在 0.3 至 0.5 区间，平均得分约为 0.41，个别扰动效果显著样本得分低至 0.01，表明系统成功扰乱声纹特征。LibriTTS 数据集评分分布相近，均值同为 0.41，最高得分略高达 0.69，最低为 0.07，反映出该数据集中部分样本在语音清晰度或风格上对扰动存在一定适应性。LibriSpeech 数据集整体得分略低，平均为 0.39，得分区间集中在 0.3 至 0.5，呈现较高稳定性。




图 3-7 数据集分布折线图

三个数据集评分曲线走势一致，得分差异不显著，这说明了本系统的扰动机制在不同语音语料、语者特征与发音风格下均表现出良好的稳定性与适应性，可适配多样化语音场景下的隐私防护需求。

(2) 主观感知评估

为了进一步验证 SonicGuard 系统在不影响语音自然度的前提下对语音进行有效扰动处理的能力，本作品研究团队设计并实施了两项基于人工主观听感打分的测评实验，结合平均意见得分（MOS）与感知说话人差异（PSD）两个指标，从音频自然度与身份感知两个维度评

估系统处理效果。

表 3-9 评分标准

分值	听感自然度评分标准（MOS）	听感差异评分标准（PSD）
1	音质极差，难以接受	几乎无差异，为同一人
2	音质较差，听感存在明显缺陷	差异较小，倾向为同一人
3	音质一般，差异较为明显	有一定差异，但仍可能为同一人
4	音质良好，存在轻微差异	有明显差异，很可能不是同一人
5	音质极佳，与原始音频无差异	差异极大，明显不是同一人

实验邀请了 20 名具有基本语音感知能力的志愿者，在不告知扰动背景的前提下，在统一的安静环境中收听随机 10 组配对音频样本（包括原始音频和经过 SonicGuard 处理后的音频），并基于五分制主观评分标准对，处理音频的听感自然度以及对听感差异进行双重打分。评分标准如表 3-9 所示。MOS 得分越高，说明音频自然度越好；PSD 得分越高，说明处理后音频与原始音频在说话人感知上的差异越大，防伪效果越明显。

实验收集到的 20 名志愿者对 10 组随机配对音频的评分数据，统计得到处理音频的平均意见得分（MOS）及感知说话人差异（PSD）分布情况，结果如表 3-10 和图 3-8 所示。

表 3-10 主观评分统计结果

样本编号	MOS 均值	PSD 均值
1	4.5	4.2
2	4.3	4.1
3	4.6	3.9
4	4.1	4.0
5	4.0	4.3
6	4.7	3.9
7	4.3	4.2
8	4.1	4.0
9	4.4	3.8
10	4.2	4.1
平均值	4.32	4.05




图 3-8 主观评分统计图

实验结果显示，经 SonicGuard 系统处理后的音频在 MOS 得分方面表现良好，10 组样本的平均 MOS 值达到 4.32，表明多数志愿者认为处理后音频在听感上与原始音频几乎无差异，并未明显降低语音质量或造成明显噪声，验证了 SonicGuard 系统实现音频防伪的同时对原始音频自然度的保持能力。同时在 PSD 打分中，样本平均得分为 4.05 分，说明处理后音频与原始音频在说话人身份感知上具有明显差异，大多数志愿者能够明确分辨二者不是同一人，说明音频防伪处理有效扰乱了声纹特征，从听觉上增强了伪造难度。

(3) 系统防御功能有效性分析

综合主客观实验结果，SonicGuard 系统在真实测试环境中展现出了良好的防御能力与用户接受度。

客观实验方面，系统调用科大讯飞声纹识别 API 对来自 3 个不同数据集的 150 条扰动样本进行相似度评估，结果显示：超过 96% 的样本相似度低于认证阈值 0.6，表明处理后音频与原始音频声纹存在明显差异，具备良好的防伪能力，有利验证了 SonicGuard 在防范基于声纹的身份克隆攻击方面的实际可行性与工程部署价值。

主观实验方面，用户听感评估测试进一步佐证了系统的实用性。20 名志愿者针对 10 组处理音频的平均意见得分（MOS）达 4.32 分，表明在多数场景下音频处理保持了良好的自然度；同时，感知说话人差异平均得分（PSD）达 4.05 分，表明大多数用户能清晰辨识处理音频与原始音频的身份差异，系统明显提升了伪造语音的可识别性。MOS 与 PSD 两项指标的协同优良表现，说明 SonicGuard 成功实现了保证音质效果与引入显著扰动的平衡目标。

4 创新性说明

在语音伪造技术日益复杂化的背景下，传统的“事后检测”方法已难以满足现代信息安全和隐私保护的需求。为了从根本上解决语音伪造问题，SonicGuard 系统提出主动防御技术路线，旨在从源头上防御语音伪造，同时确保系统的高效性和实用性。本章将详细介绍 SonicGuard 系统在防护模型、系统架构和测试评估体系方面的创新性，展示其如何为语音隐私保护提供一种全新的、主动的解决方案。

4.1 源头防御的技术原理革新落地

传统的语音伪造技术往往都集中于“事后检测”阶段，即只能检测已知的 DeepFake 语音的伪造痕迹，属于一种被动的检测模式。SonicGuard 系统突破传统被动检测模式，在语音样本发布阶段嵌入对抗扰动的主动防御逻辑。通过向原始音频中注入人耳不可察觉的细微干扰，精准破坏说话人声纹特征的提取过程，从根本上瓦解深度伪造模型对身份特征的学习能力。技术融合对抗机器学习与心理声学模型，在音频频谱的人类听觉不敏感区域（如高频段）动态生成扰动，既保证语音自然度不受明显影响，又能显著降低合成语音与原声的相似度。相比传统检测类方法，主动扰动技术具有更高的攻击适应性与平台迁移能力，尤其适用于开放平台、社交传播、语音分享等需要内容可控但无法限制下游使用场景的复杂环境，为应对泛化性强、难以追踪的语音伪造威胁提供了全新解决思路。

4.2 轻量化模块化的系统架构突破

在传统的对抗扰动计算中需要高性能 GPU 服务器，在部署层面存在比较高的成本门槛与用户技术壁垒，大大限制了其在公众层面的落地应用。SonicGuard 系统创新性地提出了“浏览器端对抗扰动实时注入机制”，选择将深度学习优化任务迁移至客户端执行，用户仅需在网页中上传音频，即可本地完成扰动注入过程，无需任何 GPU 的消耗参与。该机制核心在于将模型参数与扰动图谱进行离线预训练压缩，并通过 WebAssembly 与 JavaScript 实现轻量化推理计算，结合多线程音频帧流式加载策略，实现了在普通笔记本或移动设备中不依赖显卡的音频防护处理。在实际测试中，30 秒语音的平均扰动注入耗时低于 26 秒，系统资源占用率控制在 40%以内，远低于常规深度模型的运行负载。除此之外，该机制通过参数模板化技术

支持用户即时使进行语音防护，为构建“免部署、零安装、全场景”的语音隐私主动防护系统奠定了工程基础，实现了从模型到实际系统的部署，即使是对计算机使用不便或资源不足的群体（如老年人、低算力用户）提供了技术普惠的现实路径。分别为防护模型部分、系统构造部分、测评效果部分。这些创新点不仅是提高了语音防护的效果，更加提升了实用性方面，让技术能够快速的投入社会使用。

4.3 动态多维的测试评估体系

本系统在测试评估方面引入了动态多维的综合评估机制，不再局限于传统的识别精度或合成音质评分，而是从“安全性—实用性—可用性”三个维度构建了一套系统性评估框架。首先，在安全性评估上，构建了黑盒测试平台，选取主流合成器 TTS 进行扰动转移测试，记录扰动样本在不同 TTS 模型中的伪造成功率，验证其对抗迁移能力。其次，在实用性方面，采用科大讯飞的声纹识别接口来进行打分的评判测试，设定了 60 分以上为合格分数，更加客观且量化的展现了声纹的防护程度。更进一步，系统引入主观评价机制，邀请不同背景用户参与听辨实验，通过 A/B 测试评估音频自然度和身份差异。

综上所述，本作品设计并实现的 SonicGuard 系统在防护模型方面，突破传统“事后检测”模式，采用主动防御逻辑，在语音样本发布阶段嵌入对抗扰动，精准破坏声纹特征提取，从根本上瓦解伪造模型的学习能力，同时结合心理声学模型，确保语音自然度不受明显影响；在系统构造方面，创新性地提出“浏览器端对抗扰动实时注入机制”，将深度学习任务迁移至客户端执行，无需高性能 GPU 支持，通过 WebAssembly 与 JavaScript 实现轻量化推理计算，降低了部署成本和用户技术门槛，实现了在普通设备上的高效运行；在效果测评方面，构建了动态多维的评估体系，从安全性、实用性和可用性三个维度进行全面评估，包括黑盒测试验证对抗迁移能力、声纹识别接口评判测试以及主观听辨实验评估音频自然度和身份差异，确保系统的综合性能。SonicGuard 系统不仅提升了语音防伪造效果，更增强了实用性，为技术的快速落地应用提供了强有力的支持。

5 总结

5.1 作品总结

随着语音合成技术的快速发展，其带来的安全隐患也日益凸显。声音盗用、金融诈骗、公众人物声音滥用等问题频发，现有防御体系在面对不断进步的技术时显得力不从心。在此背景下，构建一种主动防御范式，为 DeepFake 语音治理体系提供关键技术支持具有迫切的应用价值。

本作品创新性地构建了基于对抗扰动的语音隐私主动防御系统(SonicGuard 系统)，将对抗机器学习、心理声学建模、人机协同框架与轻量化 Web 引擎深度耦合，填补了用户级 DeepFake 语音源头阻断技术在便捷性、普适性、动态防护维度的空缺。通过该系统，普通用户无需具备专业知识或高端设备，即可在日常使用中有效保护个人语音隐私。系统采用了先进的对抗机器学习算法，能够针对不同的 DeepFake 合成器生成定制化的对抗扰动，确保在各种攻击场景下都能提供可靠的防护。心理声学建模的融入则保证了添加的扰动在人耳感知上的不可察觉性，同时最大限度地破坏语音特征的可提取性。

该系统将依赖高端 GPU 的计算密集型任务转化为普通用户设备可承载的实时操作，严格继承论文防护效能，对黑盒合成器保护率 $\geq 95\%$ ，并将 3 分钟音频的处理时长缩减到低于 30 秒。这一优化得益于算法的高效实现和 WebAssembly 技术的应用，使得复杂的计算任务能够在浏览器环境中快速执行。同时，系统还支持云端处理模式，为计算资源有限的设备提供了灵活的选择。

在用户体验方面，系统确立了操作零困惑、控制可视化、信任可验证的设计哲学。用户只需通过简单的三步操作——上传音频、选择防护级别、获取处理结果，即可获得防护音频。系统提供了直观的界面，展示原始音频和受保护音频的波形图、频谱图对比，使用户能够清晰地看到防护效果。此外，系统还提供了详细的防护报告，包括音频质量评估、DeepFake 抗性分析等信息，增强用户对防护效果的信任。

系统主要分为 Web 交互平台、格式统一模块、对抗扰动生成模块、后端管理模块、深度伪造测试模块五个部分，各模块协同工作，实现音频的预处理、扰动生成、防御效果测试等功能。Web 交互平台采用了现代化的 UI 设计，提供流畅的用户体验；格式统一模块支持多种音频格式的输入输出，确保系统的兼容性；对抗扰动生成模块是系统的核心，负责生成高效

的对抗扰动；后端管理模块处理用户账户、任务队列等管理工作；深度伪造测试模块则用于验证防护效果，为用户提供客观的评估结果。

其核心原理是通过向原始音频样本中添加扰动以破坏嵌入空间，建立了数学模型，并采用基于阈值方法和汇编编码器的优化方案，提升生成的对抗样本在跨合成器场景下的可迁移性。这种方法不仅能够有效防御已知的 DeepFake 合成器，还对未知的新型合成器具有一定的泛化能力。测试采用科大讯飞提供的声纹识别 API 进行防伪测试，验证处理结果是否满足模型中的约束条件。通过大量的实验验证，系统在各种测试场景下都表现出了优异的防护性能。

在硬件与软件流程方面，明确了系统所需的硬件环境，包括操作系统、内核、CPU、GPU 等，并涵盖用户交互流程、服务请求流程、核心处理流程、任务管理流程、数据处理流程和结果返回流程，确保系统的高效运行和数据安全。系统采用了分布式架构设计，能够根据实际负载动态调整资源分配，保证服务的稳定性和响应速度。同时，严格遵循数据隐私保护法规，对用户上传的音频数据进行加密处理，确保用户数据的安全。

该系统为个人语音隐私建立了第一道防线，通过扰乱攻击者的数据供应链，为构建“检测 - 预防”协同的多层次 DeepFake 治理体系提供关键技术支撑，对遏制金融诈骗、身份盗用等现实威胁具有重要的应用价值。未来，系统还将不断优化和扩展功能，包括支持实时语音防护、多语言环境、与社交媒体平台集成等，进一步提升用户的语音安全保障水平。

5.2 推广与展望

本系统已经具有较好的实际应用性，然而目前对语音保护需求的日益增加，本系统还需要在性能、泛用性、生态、用户体验方面进行扩展，以下是项目未来的推广与展望。

1、技术优化：可引入联邦学习机制进一步提升系统性能。通过让模型在本地设备上学习用户语音特征，仅上传模型参数而非原始数据，既能保护用户隐私，又能利用大量分散数据提升模型泛化能力。同时，研发自适应扰动生成算法，使系统能根据实时检测到的合成器类型自动调整扰动策略，实现动态防护。此外，探索量子计算在语音隐私保护中的应用，提前布局未来技术挑战。

2、功能扩展：开发多模态防护功能，将语音与唇形、面部微表情等特征相结合，提供更全面的身份验证和伪造检测。推出企业级安全套件，集成实时监控、预警响应、证据链生成等功能，满足金融、政府等对安全性要求极高的行业需求。构建语音水印系统，在不影响音质的前提下嵌入不可见标识，为音频内容提供版权保护和溯源能力。

3、落地场景：在智能车载系统中，内置语音保护模块防止黑客利用合成语音下达控制指令，避免驾驶安全事故；在智能家居终端中，为语音助手提供防伪保护层，防止伪造语音获取门禁或账户权限；在远程办公与视频会议场景中，系统可作为会议接入验证前置网关，防止虚假身份劫持会议通道，保障数据安全与通信真实性；在在线教育平台中，集成语音身份识别模块，验证教师音频来源真实，确保授课过程合规、可靠。

4、生态合作：与芯片厂商合作，将语音防护算法集成到硬件中，实现更低功耗、更高性能的实时处理。与主流社交平台 and 通信应用建立 API 接口，让用户在日常使用中无缝获得防护能力。联合行业协会制定语音安全标准，推动整个行业的规范化发展。

5、用户体验：系统在提升安全性的同时，强调对用户体验的关注。未来版本将推出个性化防护配置界面，允许用户根据不同用途（如日常社交、商业录音、公开演讲等）自由调整扰动强度与音质权衡，满足多样化需求。系统还将引入语音安全等级评估功能，对上传音频样本进行自动分析，生成可视化“风险雷达图”，展示当前样本的可克隆性、攻击易感度等指标，帮助用户建立对语音隐私的感知与认知。最终防护效果将以直观安全报告形式呈现，结合频谱对比图、主观听感变化曲线与识别误差评估，提升用户对系统防护能力的可理解性与信任感。

通过以上多维度的完善和拓展，本作品将不仅局限于被动防御，更能主动塑造安全的语音生态环境，为数字时代的语音交互提供全方位、可持续的安全保障。

参考文献

- [1] Oord A, Li Y, Babuschkin I, et al. Parallel wavenet: Fast high-fidelity speech synthesis[C]//International conference on machine learning. PMLR, 2018: 3918-3926.
- [2] Liu W, Sun J, Sun Y, et al. A Speech Recognition Model Building Method Combined Dynamic Convolution and Multi-Head Self-Attention Mechanism[J]. Electronics, 2022, 11(10): 1656.
- [3] 何媛媛, 胡淼, 彭祖权, 邓贤君, 刘生昊. 语音识别对抗攻击方法综述[J]. 华中科技大学学报 (自然科学版), 2023, 51(2): 10-18.
- [4] Li Y A, Han C, Mesgarani N. Styletts: A style-based generative model for natural and diverse text-to-speech synthesis[J]. IEEE Journal of Selected Topics in Signal Processing, 2022.
- [5] Ren Y, Hu C, Tan X, et al. FastSpeech 2: Fast and high-quality end-to-end text to speech[J]. arXiv preprint arXiv:2006.04558, 2020.
- [6] Zhang H, Yuan T, Chen J, et al. PaddleSpeech: An easy-to-use all-in-one speech toolkit[J]. arXiv preprint arXiv:2205.12007, 2022.
- [7] Wang K, Chen M, Lu L, et al. From one stolen utterance: Assessing the risks of voice cloning in the aigc era[C]//2025 IEEE Symposium on Security and Privacy (SP). IEEE, 2025: 4663-4681.
- [8] Zhang C Y, Yi J, Tao J, et al. Distinguishing neural speech synthesis models through fingerprints in speech waveforms[C]//China National Conference on Chinese Computational Linguistics. Singapore: Springer Nature Singapore, 2024: 259-273.
- [9] Yang J, Lin P, He Q. Constant - Q magnitude - phase coefficients extraction for synthetic speech detection[J]. IET Biometrics, 2020, 9(5): 216-221.
- [10] Variani E, Lei X, McDermott E, et al. Deep neural networks for small footprint text-dependent speaker verification[C]//2014 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2014: 4052-4056.
- [11] Snyder D, Garcia-Romero D, Sell G, et al. X-vectors: Robust dnn embeddings for speaker recognition[C]//2018 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2018: 5329-5333.
- [12] Desplanques B, Thienpondt J, Demuynck K. Ecapa-tdnn: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification[J]. arXiv preprint

arXiv:2005.07143, 2020.

- [13] Baevski A, Zhou Y, Mohamed A, et al. wav2vec 2.0: A framework for self-supervised learning of speech representations[J]. Advances in neural information processing systems, 2020, 33: 12449-12460.
- [14] Yu Z, Zhai S, Zhang N. Antifake: Using adversarial audio to prevent unauthorized speech synthesis[C]//Proceedings of the 2023 ACM SIGSAC Conference on Computer and Communications Security. 2023: 460-474.
- [15] Dong S, Chen B, Ma K, et al. Active Defense Against Voice Conversion through Generative Adversarial Network[J]. IEEE Signal Processing Letters, 2024, 31: 706-710.
- [16] Li Z, Shi C, Zhang T, et al. Robust detection of machine-induced audio attacks in intelligent audio systems with microphone array[C]//Proceedings of the 2021 ACM SIGSAC Conference on Computer and Communications Security. 2021: 1884-1899.
- [17] Zhou J, Yi J, Ren Y, et al. WMCodec: End-to-End Neural Speech Codec with Deep Watermarking for Authenticity Verification[J]. arXiv preprint arXiv:2409.12121, 2024.
- [18] Peng P, Huang P Y, Li S W, et al. Voicecraft: Zero-shot speech editing and text-to-speech in the wild[J]. arXiv preprint arXiv:2403.16973, 2024.
- [19] Zhang J, Dai L, Xu L, et al. Black-box watermarking and blockchain for ip protection of voiceprint recognition model[J]. Electronics, 2023, 12(17): 3697.
- [20] Mari D, Salvi D, Bestagini P, et al. All-for-one and one-for-all: Deep learning-based feature fusion for synthetic speech detection[C]//Joint European Conference on Machine Learning and Knowledge Discovery in Databases. Cham: Springer Nature Switzerland, 2023: 469-479.
- [21] Fedushko S, Syerov Y, Kryvinska N. AntiFake System: Machine Learning-Based System for Verification of Fake News[J]. Procedia Computer Science, 2024, 238: 663-670.
- [22] Li J, Chen C, Azghadi M R, et al. Security and privacy problems in voice assistant applications: A survey[J]. Computers & Security, 2023, 134: 103448.
- [23] Khochare J, Joshi C, Yenarkar B, et al. A deep learning framework for audio deepfake detection[J]. Arabian Journal for Science and Engineering, 2021: 1-12.
- [24] 杨清赵岗岗柏文杰张圣道. 改进阈值函数下的小波阈值降噪[J].工业控制计算机,

2020,33(4):97-98.

- [25] Clevert D A, Unterthiner T, Hochreiter S. Fast and accurate deep network learning by exponential linear units (elus)[J]. arXiv preprint arXiv:1511.07289, 2015.
- [26] Qi X, Wei Y, Mei X, et al. Comparative analysis of the linear regions in ReLU and LeakyReLU networks[C]//International Conference on Neural Information Processing. Singapore: Springer Nature Singapore, 2023: 528-539.
- [27] Qiu S, You X, Rong W, et al. Boosting Imperceptibility of Adversarial Attacks for Environmental Sound Classification[C]//2024 IEEE 36th International Conference on Tools with Artificial Intelligence (ICTAI). IEEE, 2024: 790-797.
- [28] Dhara S, Chatterjee I, Kumar H, et al. Comodulation masking release effect in children with and without dyslexia[J]. International Journal of Otorhinolaryngology and Head and Neck Surgery, 2020, 6(8): 1477.
- [29] Panayotov V, Chen G, Povey D, et al. Librispeech: an asr corpus based on public domain audio books[C]//2015 IEEE international conference on acoustics, speech and signal processing (ICASSP). IEEE, 2015: 5206-5210.
- [30] Zen H, Dang V, Clark R, et al. Libritts: A corpus derived from librispeech for text-to-speech[J]. arXiv preprint arXiv:1904.02882, 2019.
- [31] Nagrani A, Chung J S, Zisserman A. Voxceleb: a large-scale speaker identification dataset[J]. arXiv preprint arXiv:1706.08612, 2017.
- [32] Kearns J. Librivox: Free public domain audiobooks[J]. Reference Reviews, 2014, 28(1): 7-8.
- [33] Streijl R C, Winkler S, Hands D S. Mean opinion score (MOS) revisited: methods and applications, limitations and alternatives[J]. Multimedia Systems, 2016, 22(2): 213-227.
- [34] Perrachione T K, Furbeck K T, Thurston E J. Acoustic and linguistic factors affecting perceptual dissimilarity judgments of voices[J]. The Journal of the Acoustical Society of America, 2019, 146(5): 3384-3399.
- [35] Nishizaki H. Data augmentation and feature extraction using variational autoencoder for acoustic modeling[C]//2017 Asia-Pacific Signal and Information Processing Association Annual Summit and Conference (APSIPA ASC). IEEE, 2017: 1222-1227.

-
- [36] Ankişhan H. An approach to the classification of environmental sounds by LSTM based transfer learning method[C]//2020 28th Signal Processing and Communications Applications Conference (SIU). IEEE, 2020: 1-4.
- [37] Kantamaneni S, Charles A, Babu T R. Speech enhancement with noise estimation and filtration using deep learning models[J]. Theoretical Computer Science, 2023, 941: 14-28.
- [38] 顾煜, 金赟, 马勇, 等. 基于声学 and 文本特征的多模态情感识别[J]. Journal of Data Acquisition & Processing/Shu Ju Cai Ji Yu Chu Li, 2022, 37(6).